

期末展示

吴宇茜 2023200727

2025.12.25

文本处理-CPU权衡

两种方法:

- sentence-transformers/paraphrase-MiniLM-L3-v2

文本特征提取阶段采用了 SentenceTransformers 框架下的 paraphrase-MiniLM-L3-v2 模型，将自然语言文本高效映射到语义空间，从而量化客户反馈与房产描述的情感倾向。

这个模型足够小使得在CPU上不会构成严重负担.(此外,模型使用结束时释放内存,为后续交叉验证腾出空间)

- 简单词典匹配法(如果前述方法下载huggingface模型失败)

非线性模型的运用

- 随机森林

通过拟合不相同的树来降低单一决策树的高方差问题.

- lightgbm(如果不可用也会回退GradientBoostingRegressor)

结果表明,lightgbm性能和随机森林相似,但是时间更短,模型更加轻量化.

运行结果展示

sell:

	Model	InSample_RMSE	OutSample_RMSE	CV_RMSE
	OLS	1.265456e+06	1.250974e+06	1.268705e+06
	RandomForest	3.251670e+05	7.352932e+05	7.809026e+05
	LightGBM	3.250296e+05	5.963182e+05	6.292759e+05

rent:

	Model	InSample_RMSE	OutSample_RMSE	CV_RMSE
	OLS	360427.490437	362736.490982	360821.345350
	RandomForest	88550.621744	196146.461669	201657.526834
	LightGBM	117436.151772	196761.985724	196937.937300

kaggle	OLS	RandomForest	lightgbm
	59.7	73.7	73.8