

Housing Price and Rent Prediction

Final Exam: Hackathon

陈君昊 2023200740

Renmin University of China

2023 Dual Bachelor's Degree Program in Econ and Math

December 25, 2025

语义特征工程与模型 1 策略

A. 基于 RoBERTa 的文本分析

- 捕捉非结构化文本 (如 “核心卖点”、“客户反馈”) 中的信息, 弥补结构化数据的不足.
- **NLP 特征提取:** 采用预训练的**中文 RoBERTa 模型** (hfl/chinese-roberta-wwm-ext), 使用特征提取模式并冻结模型参数, 对所有 token 表征做平均池化, 将文本映射为 768 维向量.

B1. 模型 1: PCA-LGBM

- 树模型 (LightGBM) 直接处理 768 维向量时面临维度灾难 $\Rightarrow$ 过拟合.
- 使用**主成分分析 (PCA)** 将 768 维向量压缩至 **64 个主成分** (保留约 70% 方差).
 - 将 64 维语义特征与原始表格特征拼接, 使模型能有效利用文本信息, 同时避免过拟合.


B2. 模型 2: 并行集成策略 (LGBM+Keras)

- 并行训练 LightGBM 与深度学习模型, 再融合结果 $\Rightarrow$ 结合 LightGBM 强大的拟合能力与神经网络优异的泛化性能.
- B2-1. 使用结构化数据训练 LightGBM, 超参数通过 20% 降采样 Optuna 优化.
- 采用 **6 折模型平均** (类似袋装法), 最终预测为 6 个模型的均值 $\Rightarrow$ 降低方差.

模型 2 策略: 深度学习与岭回归堆叠集成

B2-2. 基于 Keras 的双头神经网络

- 网络结构: 双头架构.
 - A 分支: 处理标准化的表格数据 (925/233 维).
 - B 分支: 输入 768 维 NLP 向量, 独立提取高维语义特征.
- 稳定性优化: $\log Price$ 逆变换放大误差 $\Rightarrow$ 梯度爆炸.
 - 改用 Huber Loss, 结合 L2 正则化、高 Dropout 率 (0.4) 及输出截断, 约束预测区间.



B2-3. 元学习器: 岭回归堆叠集成

- 将 LightGBM 与双头神经网络的输出进行加权融合.
- 采用岭回归作为元学习器, 求解最优权重, 处理子模型输出的共线性, 最小化全局误差.

Model Performance: RMSE & Kaggle Score

Price Data					Rent Data				
Model	In	OOS	CV	KS	Model	In	OOS	CV	KS
Elastic Net	977k	1155k	1725k	68.9	Elastic Net	270k	264k	461k	68.9
PCA-LGBM	265k	629k	738k	74.7	PCA-LGBM	79k	176k	201k	74.7
LGBM	253k	568k	516k	76.8	LGBM	82k	161k	172k	76.8
Keras	1186k	1124k	1124k	72.4	Keras	222k	226k	226k	72.4
LGBM+Keras	–	–	1,051k	77.9	LGBM+Keras	–	–	167k	77.9

In = In-sample RMSE, **OOS** = Out-Of-Sample RMSE, **CV** = six-fold Cross-Validation RMSE, **KS** = Kaggle Score (from combined price and rent predictions per model). All values in thousands (k).