



中國人民大學

期末项目展示

郑瑜 2023200769

数据清洗

特征工程

模型训练

Random Forest

Xgboost

LightGBM

task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
rent	XGB	0.2599	0.2662	0.2678	63.2
rent	LGB	0.2646	0.269	0.2722	62.9
rent	RF	0.3716	0.3778	0.3755	49.9
rent	best (XGB)	0.2599	0.2662	0.2678	63.2

task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
price	XGB	0.2792	0.284	0.2865	63.2
price	LGB	0.2851	0.2884	0.2922	62.9
price	RF	0.404	0.4105	0.4096	49.9
price	best (XGB)	0.2792	0.284	0.2865	63.2



特征重要性

Feature importance for Tree based 内置重要性

Permutation Importance 置换重要性

SHAP value

二轮特征筛选
和模型训练



如何筛选?

1. 计算特征累积贡献 `np.cumsum`

50个



2. 将三种重要性结合

单种重要性内三选二投票模式选出每种重要性的核心特征










在此基础上并上三种模型都认可的核心特征

房价任务 (Price) 筛选完成! 保留特征数: 67
特征示例: ['建筑面积', '梯户比例', '年份', '...', '停车位', '停车费用', '房屋用途_Commercial']

租金任务 (Rent) 筛选完成! 保留特征数: 74

没有依赖单一的 `feature_importances_`
通过结合三种模型, 平衡了模型可能存在的偏见

剔除了大量的共线性 (冗余) 特征和噪声



特征从 900+ 骤减到 60+ (缩减了 90% 以上), 但 各模型的 CV RMSE 依然保持稳定甚至有个别略有下降。

结论: 这说明原始数据中存在极大的多重共线性和无效噪声。大量被踢出的特征并不能提供额外的预测增量。

```
joblib.dump(package,  
file_name)
```

持久存储

在调试代码时不需要反复跑代码, 提高效率

随时可供调用和查看 (包括指标信息)

task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
rent	XGB	0.2599	0.2662	0.2678	63.2
rent	LGB	0.2646	0.269	0.2722	62.9
rent	RF	0.3716	0.3778	0.3755	49.9
rent	best(XGB)	0.2599	0.2662	0.2678	63.2
task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
price	XGB	0.2792	0.284	0.2865	63.2
price	LGB	0.2851	0.2884	0.2922	62.9
price	RF	0.404	0.4105	0.4096	49.9
price	best(XGB)	0.2792	0.284	0.2865	63.2

减少前

task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
rent	XGB	0.2586	0.2656	0.266	63.3
rent	LGB	0.2659	0.2712	0.2723	62.7
rent	RF	0.3616	0.3676	0.364	50.2
rent	best(XGB)	0.2586	0.2656	0.266	63.3
task	model	in-sample RMSE	out-of-sample RMSE	CV RMSE	Kaggle
price	XGB	0.2717	0.2776	0.2799	63.3
price	LGB	0.28	0.2849	0.2875	62.7
price	RF	0.4081	0.4159	0.4087	50.2
price	best(XGB)	0.2717	0.2776	0.2799	63.3

减少后



中國人民大學

谢谢！