


文本特征与城市异质性：房地产预测建模

许家淼 2023201777

2025 年 12 月

LLM & PCA: 解锁文本特征

- 线性模型的改进
 - 量化房屋的“非数量特征”（如装修品味、居住体验、物业管理评价）
 - 中期模型仅依赖数值回归，丢失了大量非结构化文本中的高维信息
- 引入 **shibing624/text2vec-base-chinese** (BERT 架构)，将文本转化为 768 维的向量
- 降维策略：
 - Price: **PCA=50 维**，'核心卖点'，'户型介绍'，'周边配套'，'交通出行'，'客户反馈'，信息保留率：70.02%
 - Rent: **PCA=25 维**，“客户反馈”，信息保留率：58.85%
- Gain 特征重要性分析




“城市异质性” 的建模与参数估计策略

- **捕捉城市差异性**: 引入城市虚拟变量 (One-Hot Encoding), 反应数据分布不均衡
 - 'city': [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11]
 - 'sample_count': [16491, 6437, 24996, 21472, 4363, 3582, 2281, 1184, 5931, 1323, 15057, 754]
- **步骤 1: 调树结构参数** max_depth: [4, 6, 8], min_child_weight: [1, 3, 5]
 - **max_depth=8** (较深) 和 **min_child_weight=1** (高敏感度)
- **步骤 2: 调随机性参数** subsample: [0.6, 0.8, 1.0], colsample_bytree: [0.6, 0.8, 1.0]
 - **subsample=0.8 & colsample_bytree=0.8** 从局部特征中学习, 增强模型稳健性
- **步骤 3: 调正则化参数** reg_alpha: [0, 0.1, 1], reg_lambda: [1, 2, 5]
 - 正则化约束: **reg_alpha=0.1®_lambda=1**, 模型在 PCA 降维特征上表现稳健无需正则约束
- 早停, 低学习率、收缩策略: 最终采用 **Learning Rate 0.01 + 10,000 Trees + Early Stopping (100 rounds)**, 平衡偏差与方差

性能表现与特征分析

特征重要性分析:



模型性能对比:

Prediction Task	Exam Stage	Model Type	In-Sample MAE	Out-of-Sample MAE	Kaggle Score
Housing Price	Midterm	Linear Baseline (OLS)	687,509.15	672,358.92	34.4→66
	Final	XGBoost + NLP Features	86,815.24	281,152.11	
Housing Rent	Midterm	Linear Baseline (OLS)	161,839.70	160,167.64	
	Final	XGBoost + NLP Features	26,217.65	77,394.02	