

创新点一：打破“年份”桎梏——引入宏观经济周期

从“线性数字”到“市场水位”的思维跃迁

1. 思考原点：为什么“年份”不能只是数字？

- **痛点**：传统模型将 2019 到 2021 视为简单的 +2 关系，隐含假设是房价随时间线性折旧或增值。
- **直觉**：中国楼市具有强烈的政策导向和周期性。2021 年的高点是由于信贷宽松，而非房子本身变好了。
- **结论**：模型必须“感知”当年的市场热度，而非仅仅知道是哪一年。

2. 解决方案：宏观数据映射 (Macro-Mapping)

我们将单一的 Year 变量扩展为多维经济指标：

- **锚定水位**：引入当年该城市的二手房价格指数 (Price Index)，作为基准锚点。
- **量化杠杆**：引入当年的 5 年期 LPR 利率，量化购房成本。

$\text{Feature}_{\text{year}} \xrightarrow{\text{Mapping}} [\text{CPI}, \text{Interest_Rate}, \text{GDP_Growth}]$

效果：即使遇到训练集中未出现的年份，模型也能根据宏观指标推断价格水位。

创新点二：文本数据的“分而治之”策略

拒绝“一刀切”：针对不同文本属性定制处理逻辑

核心思路：并非所有文本都需要深度学习。我们将文本分为“硬指标”和“软描述”两类，分别处理以兼顾精度与深度。

1. 硬指标文本 (Structured-like)

- **对象：**交通出行、配套设施
- **特点：**包含“地铁”、“满五唯一”、“距站500米”等决定性关键词。
- **处理方案：专家规则系统 (Expert Rules)**
 - 利用 **Regex** 精准提取数字（如距离米数）。
 - 构建 **Tagging System**，将特定短语暴力映射为 0/1 特征）。
- **优势：**可解释性强，绝对不会漏掉“学区”这种强特征。

2. 软描述文本 (Unstructured)


- **对象：**核心卖点、出租原因
- **特点：**包含“房东急售”、“装修豪华”、“诚心置换”等情绪化、隐含溢价信息。
- **处理方案：BERT 语义向量化**
 - 调用预训练模型 `bert-base-chinese`。
 - 提取 [CLS] 向量并 PCA 降维，捕捉字面背后的紧迫感与档次感。
- **优势：**捕捉非线性语义，填补规则无法覆盖的“感觉”空白。

创新点三：异构集成学习 (Heterogeneous Ensemble)

集众家之长：XGBoost + LightGBM + CatBoost

1. 为什么要用三个模型？(Model Diversity)

- **单一模型的局限**：XGBoost 虽然稳健，但对我们生成的大量 BERT 降维特征（连续值）和 Tag 特征（稀疏值）可能存在处理偏好。
- **互补性设计**：
 - **CatBoost**：处理我们特征工程中产生的大量类别特征（Categorical Features）具有天然优势，且不易过拟合。
 - **LightGBM**：基于 Leaf-wise 生长策略，对非线性模式捕捉更敏锐。
 - **XGBoost**：作为基石，保证整体预测的方差稳定性。



最终收益

通过 **Weighted Blending**，我们在保留了文本特征深度（BERT）的同时，利用集成学习平滑了预测噪声，能实现比单模型更好的结果。