



中國人民大學

RENMIN UNIVERSITY OF CHINA

Housing Price and Rent Prediction

Final Project Achievement Presentation

袁博辰 2023201780

實事求是

Model Performance : MAE & Kaggle Score



中國人民大學
RENMIN UNIVERSITY OF CHINA

Price:

Model	In sample rmse	Out of sample rmse	Cross-validation rmse	Kaggle Score
Ridge	939.57k	1041.55k	1189.29k	69.5
Random Forest	343.20k	714.68k	1012.84k	73.1
ANN	292503.00k	1077.99k	2711.08k	69.4
Best Model	343.20k	714.68k	1012.84	73.1

Rent:

Model	In sample rmse	Out of sample rmse	Cross-validation rmse	Kaggle Score
Ridge	266.15k	229.75k	358.19k	69.5
Random Forest	80.73k	164.43k	330.46k	73.1
ANN	313682.70k	215.68k	2878.70k	69.4
Best Model	80.73k	164.43k	330.46k	73.1

1. **将房产的非结构化文本信息（核心卖点、户型介绍、客户反馈等）转化为可建模的结构化特征：**① 合并多文本列并做中文清洗（标点归一、去停用词）；② 基于 jieba 分词 + TF-IDF 提取文本关键词特征（限制100or50维、1-2元词汇，规避高维灾难）；③ 对客户反馈做情感分析（SnowNLP 情感得分 + 负面 / 中性 / 正面哑变量），挖掘文本中的价值信号。
2. **地理特征的细粒度算法化建模：**突破传统“行政区划分组”的粗粒度区位特征，基于经纬度用 K-Means (n_clusters=150) 实现商圈 / 小区级细粒度地理聚类，精准捕捉“同聚类房源价格 / 租金趋同”的区位规律，将隐性地理价值转为显性特征。
3. **鲁棒性评估指标计算工具：**针对房价 / 租金 Log 反转换后易出现 inf/nan/ 极端值导致评估指标失效的问题，创新采用“分位数范围限定 + 异常值均值替换”的双层鲁棒处理策略，基于真实值 0.1%/99.9% 分位数划定合理数值区间，既解决了 Log 反转换的数值异常问题，又过滤了房产数据中的极端值干扰，保证 MAE/RMSE/R² 等评估指标能反映绝大多数普通房源的真实预测精度。


PDP Analysis




中國人民大學
RENMIN UNIVERSITY OF CHINA

特征重要性与可解释性的多模型适配创新：针对 Ridge（系数绝对值）、RandomForest（内置重要性）、ANN（排列重要性）三类模型，定制化实现特征重要性量化逻辑，同时结合 PDP 可视化将抽象模型规律转化为业务可解读的边际效应，突破了 ANN “黑箱” 模型的可解释性痛点。

RandomForest模型 - 房价 Top3特征部分依赖图 (Log尺度)



RandomForest模型 - 租金 Top3特征部分依赖图 (Log尺度)



模型特性差异：线性模型（Ridge）更关注基础结构特征的直接关联；树模型（RandomForest）能捕捉生活成本等隐性非线性关联；ANN 适配高维特征，更侧重复杂户型 / 区位的组合影响。

业务逻辑差异：房价是资产价值，依赖房间数、建筑年代等长期属性；租金是短期使用成本，更受燃气费、停车费等日常支出，以及区位（聚类）的即时配套影响。

实事求是