


量化建模期末报告

王子涵

多模态语义感知 (BERT) & 图注意力网络 (GAT)


- text_features = ["核心卖点", "周边配套", "交通出行", "客户反馈"]
- 语句文段类信息，期中选择直接删去
- 期末：部署预训练 **BERT** 模型。
- **上下文理解**性训练，将模糊的描述转化成高质量的**稠密语义向量**
- 任务匹配度：文本生成Decoder ✗
特征提取Encoder ✓
- 数值稳定性：确定结果，避免幻觉
- 计算效率：本地部署， 15min ✓
- 提取完成 PCA降维 768*4 ----> 10*4

- **地理信息** 的处理
- 期中：TE-Encoding & K-means 聚类
- 期末：KNN构建图 & GATv2 动态注意力网络
- 构建网络—— **KNN** 算法 (k=5)
- 权重训练—— **GATv2** 动态注意力
- GCN? 平均邻居权重
- GAT 根据特征的相似度，**动态调整**聚合邻居信息的权重
- 输出：16 维的空间嵌入向量 高度浓缩**地段价值**
- 仍然 保留 K-means结果作为 特征！ **宏观位置+微观拓扑**



监督式流形学习 S-VAE

- 特征还能进化吗?
- **特征增强**
- **S-VAE** 基于残差神经网络 对变量进行压缩 降维
- 我们用于输出特征 得到的是 高维去噪 特征 *16
- **S-VAE** 的神经网络结构 (ResNet) : 残差连接 输入 x 直接加到输出上 $x + \text{block}(x)$
- 主体: 压缩、重构和预测



- 编码器 (Encoder) 200->128 残差块叠加 提取**深层非线性特征**
- 隐变量层 (Latent Layer) 分布的 **均值** 和 **方差**
- 解码器 (Decoder) 16维隐变量还原原始数据 减小信息损失
- **回归器 (Regressor)** 16维隐变量预测房价 z 包含决定房价的关键因子 (Supervised)
- 重参数化 & 向前传播 优化损失函数
- 效果奇佳!!
- Kaggle 70.7-->74.1
- 互补效应: 原始数据 微观精确
- S-VAE 特征 宏观 非线性 高信噪比 连续平滑的流形结构

多模型集成

- 多样化 基模型
- Tree-based: **XGBoost, LightGBM, CatBoost.**
- 捕捉非线性特征和特征交互
- Neural Network: **MLP** 引入**差异性**
- 极致的超参数优化
- **Optuna** 用于XGBoost/LGBM/CatBoost
- 大范围搜索。更快找到全局最优解。
- **GridSearchCV:**
- 用于模型微调
- 确保在局部最优解附近找到最佳参数。
- **Stacking** 集成策略
- 4 个基模型预测结果作为新特征
- 输入到简单的 Ridge Regression 或 Linear Regression 进行加权融合。
- 结合了各家之长，Bias和Varianc同时降低。

	Base LGBM	Optuna Best (MAE 213329)	LGBM (v4: n=2000, lr=0.05)	XGBoost Optuna (MAE 222877)	Optuna MLP	CatBoost Optuna (MAE 230577)	Stacking (M
AE 211243)							
MAE_in	271,919	N/A	103,019	N/A	N/A	N/A	N/A
N/A							
RMSE_in	592,091	N/A	211,202	N/A	N/A	N/A	N/A
N/A							
MAE_out	295,973	213,329	212,390	222,877	262,463	230,577	
211,243							
RMSE_out	660,000	498,295	495,547	526,538	586,777	N/A	
N/A							
MAE_cv	N/A	N/A	223,524	N/A	N/A	N/A	N/A
N/A							

--- Stacking 权重分析 (元模型系数) ---

LGBM 0.772460

XGBoost 0.255016

CatBoost 0.069548

MLP -0.090884

dtype: float64

截距 (Intercept): -0.0889

🏆 Stacking (拟合后) MAE: 211,242.54

2. 训练元模型 (Ridge Regression)...

--- 🏆 各模型贡献权重 ---

LGBM 0.739904

XGB 0.248610

Cat 0.034923

MLP -0.022423

dtype: float64

>>> Stacking (验证集) MAE: 69,630.68

- **LGBM** 最优模型 绝对主导
- 单独训练效果绝佳 **76.6**
- **XGBoost** 的有效辅助
- MLP 权重为负?
- 纠偏：减去部分 MLP 的预测值，以抵消树模型的偏差，从而降低整体的方差。
- MLP 在这里起到了 **对冲风险** 的作用
- 集成学习**多样性**
- **Midterm 67.5**
- **76.6 (LGBM) -->**
- **76.1 (LGBM+XGBoost) -->**
- **70.7 (LGBM+XG+Cat+MLP) ?**
- 过拟合 方差减小 偏差变大