

Housing Price and Rent Prediction

Midterm Project: Quant Modeling for Data Scientists

白瑞睿 2023200753

陈君昊 2023200740

郑瑜 2023200769

Renmin University of China

2023 Dual Bachelor's Degree Program in Econ and Math

October 30, 2025

Data Processing

数据准备

- **清洗**: 统一数值格式 (费用/比率); Winsorize (5%/95%) 处理异常值。
- **编码**: 分类特征转为哑变量 (`get_dummies, drop_first=True`); '未知' 填充缺失。
- **列删减**: 移除所有文本、高基数、无关及冗余列 (如坐标/区域, 已由聚类替代)。
- **缺失值**: 对所有剩余特征 (包括工程特征) 统一使用中位数填充 (`SimpleImputer`)。

Feature Engineering

挑战: 线性模型难以捕捉位置与户型对价格的复杂非线性影响。

策略一: K-Means 地理聚类 (k=150)

- 标准化 lon/lat → K-Means 拟合训练集 → 预测所有点
- 聚类标签 → 哑变量 (cluster_*)
- 优势:

策略二: 精细化户型特征

- 从“房屋户型”文本中分别提取 num_ 室, num_ 厅, num_ 厨, num_ 卫
- 根据不同户型生成虚拟变量
- 优势: 相比计算“房间总数”等方法,为模型提供了更精确的户型信息

其他特征: 楼层总数, 梯户比例, 每栋房屋数; 建筑年代分箱, 建筑面积/面积分箱

Model Performance

最优模型 (基于 6 折 CV MAE):

- **房价:** Ridge / ElasticNet (CV MAE $\approx$ 1,081k)
- **租金:** Ridge / ElasticNet (CV MAE $\approx$ 285k)

(注: 结果使用先前优化好的固定超参数)

MAE 解读:

- 我们的最优房价模型 CV MAE 约为: **108 万**。
- 我们的最优租金模型 CV MAE 约为: **28.5 万**。

总结:

- 遵循项目要求使用线性模型并进行了系统的数据准备。
- **核心贡献:** 通过 K-Means 聚类 and 精细化户型特征, 有效提升了受限线性模型的性能。
- 正则化模型 (ElasticNet/Ridge) 表现远优于 OLS, 成功控制了高维特征。

Group Model Performance: MAE & Kaggle Score

Price Data

Model	In	OOS	CV	KS
OLS	421k	1,622k	5,107k	69.2
LASSO	565k	553k	1,173k	63.9
Ridge	428k	436k	1,081k	68.9
Elastic Net	428k	435k	1,081k	68.9

Rent Data

Model	In	OOS	CV	KS
OLS	107k	107k	361k	69.2
LASSO	109k	109k	308k	63.9
Ridge	111k	110k	285k	68.9
Elastic Net	110k	109k	285k	68.9

In = In-sample MAE, **OOS** = Out-of-sample MAE, **CV** = Cross-validation MAE, **KS** = Kaggle Score (from combined price and rent predictions per model). All values in thousands (k).