

Housing Price and Rent Prediction

Midterm Project: Quant Modeling for Data Scientists

白瑞睿 2023200753

陈君昊 2023200740

郑瑜 2023200769

Renmin University of China

2023 Dual Bachelor's Degree Program in Econ and Math

October 30, 2025

Data Processing

清洗: 统一数值格式 (费用/比率); Winsorize (5%/95%) 处理异常值。

- 正则提取数字 (by 郑): eg. "2.8-3.2 元 / 月" $\rightarrow$ [2.8,3.2] $\rightarrow$ 3.0
- 中文数字转整数 (by 白): eg. "一梯两户" $\rightarrow$ 1,2 $\rightarrow$ 2/1=2.0
- Winsorize (by 郑): 保留样本量, 避免有效信息丢失, 不浪费数据价值

编码: 分类特征转为哑变量 (get_dummies, drop_first=True); "未知" 填充缺失。

- "房屋用途" (by 陈): 多类别归并 - 写字楼、商业、商业办公类、商住两用、底商 $\rightarrow$ 房屋用途 _Commercial; 住宅式公寓、公寓、酒店式公寓 $\rightarrow$ 房屋用途 _Apartment ... 类别共 5 个 (减少特征维度, 避免"维度灾难", 降低过拟合风险)
- "产权描述" (by 郑): 解决一个样本属于多个类别, eg. 商品房/央产房/私产/军产 $\rightarrow$ 产权描述 _商品房 = 1、产权描述 _央产房 = 1...
- "楼层" (by 白): 统一格式设置虚拟变量, 保留总楼层和楼层高矮信息, eg. 18\31 层 $\rightarrow$ 31*1/3 < 18 < 31*2/3 $\rightarrow$ 楼层类别 _中楼层 (共 31 层) = 1; 低楼层\15 层 $\rightarrow$ 楼层类别 _低楼层 (共 15 层) = 1

列删减: 移除所有文本、高基数、无关及冗余列 (如坐标/区域, 已由聚类替代)。

缺失值: 对所有剩余特征统一使用中位数填充 (SimpleImputer)。

Feature Engineering

通过合理的特征工程设计,让线性模型捕捉复杂房价模式。

策略一 (by 陈):K-Means 地理聚类 (k=150)

- 标准化 lon/lat → K-Means 拟合训练集 → 预测所有点
- 聚类标签 → 虚拟变量 (cluster_*)
- 优势:捕捉不同地区之间房价的差异;只在训练集上拟合聚类模型,防止数据泄漏

策略二 (by 白):精细化户型特征处理

- 从“房屋户型”文本中分别提取室、厅、厨、卫数量
- 根据不同户型创建虚拟变量
- 创新:基于建筑面积的智能房间数量缺失值填补

策略三 (by 陈):变量分箱

- 对建筑年代、面积等连续变量进行分位数分箱
- 分箱结果 → 虚拟变量
- 优势:让线性模型分段学习非线性关系

其他特征: 楼层分类, 梯户比例, 每栋房屋数

Model Performance

特征准备与特征对齐

最优模型 (基于 6 折 CV MAE):

- 房价: Ridge / ElasticNet (CV MAE = 1,081k)
- 租金: Ridge / ElasticNet (CV MAE = 285k)
 - Kaggle score = 68.9

总结:

- 遵循项目要求使用线性模型并进行了系统的数据准备。
- 通过 K-Means 聚类 and 精细化户型特征, 有效提升了受限线性模型的性能。
- 正则化模型 (ElasticNet/Ridge) 表现优于 OLS, 成功控制了高维特征。

Group Model Performance: MAE & Kaggle Score

Price Data

Model	In	OOS	CV	KS
OLS	421k	1,622k	5,107k	69.2
LASSO	565k	553k	1,173k	63.9
Ridge	428k	436k	1,081k	68.9
Elastic Net	428k	435k	1,081k	68.9

Rent Data

Model	In	OOS	CV	KS
OLS	107k	107k	361k	69.2
LASSO	109k	109k	308k	63.9
Ridge	111k	110k	285k	68.9
Elastic Net	110k	109k	285k	68.9

In = In-sample MAE, **OOS** = Out-of-sample MAE, **CV** = Cross-validation MAE, **KS** = Kaggle Score (from combined price and rent predictions per model). All values in thousands (k).