

Group 4 小组展示

小组成员:潘晓语,陶绪志,吴宇茜,袁博辰

亮点 1：稳健的 ONE-HOT 编码策略—— “Top-N 降维” + “其余归类”

数据存在大量高基数分类特征（如 板块），直接 ONE-HOT 编码会造成维度爆炸和模型过拟合。

（但是注意保证稳健性和可复用性质，后续可以更完善）

亮点 2：精细化数据清洗：区域级异常值过滤 -- “ppsm” + “区域分组 3-IQR”

数据具有极强的地域性，简单的全局过滤无法区分正常的高价值数据和真正的错误数据（如价格多写一个零）。

【kept 98135/98899】

（依赖于原始数据中城市或区域字段的完整性和判断精确程度）

结果反思：数值爆炸：从 OLS 崩溃到 Ridge 稳健预测

Price 模型在初始诊断中，Cross-validation R^2 发生数值爆炸，特征空间存在严重的多重共线性

eg:有燃气&供热费\当前楼层&楼层级别\虚拟变量陷阱（精装、简装、毛坯）

🏆 Kaggle 分数汇总

Kaggle Score	
模型	
OLS	54.73
Lasso	54.26
Ridge	54.68
ElasticNet	54.47

📊 Price 数据集模型评估汇总 (R^2 为 Log Scale, MAE 为原始量纲)

	OLS	RidgeCV ($\alpha=1.0$)	LassoCV ($\alpha=0.0001$)	ENetCV ($\alpha=0.0001$, $L1r=0.10$)
In-sample R^2	0.6510	0.6510	0.6507	0.6509
Out-of-sample R^2	0.6408	0.6408	0.6406	0.6408
Cross-validation R^2	**Exploded!**	N/A	N/A	N/A
In-sample MAE (Orig)	872,135.55	872,109.05	871,907.59	871,858.38
Out-of-sample MAE (Orig)	868,807.39	868,726.10	868,993.04	868,663.78

📊 Rent 数据集模型评估汇总 (R^2 为 Log Scale, MAE 为原始量纲)

	OLS	RidgeCV ($\alpha=1.0$)	LassoCV ($\alpha=0.0001$)	ENetCV ($\alpha=0.0001$, $L1r=0.10$)
In-sample R^2	0.6906	0.6906	0.6906	0.6906
Out-of-sample R^2	0.6990	0.6990	0.6990	0.6990
Cross-validation R^2	0.6897	N/A	N/A	N/A
In-sample MAE (Original)	188,736.56	188,716.28	188,765.43	188,722.04
Out-of-sample MAE (Original)	184,938.26	184,925.88	184,972.00	184,929.71

亮点1：智能特征选择 – Lasso降维

Lasso的L1正则化 会自动让不重要特征的系数变成0，只保留绝对值最大的50/60个特征，既保留了关键信息，又大幅降低维度，维度 – 38%，训练速度↑，泛化能力

最后结果，ridge、ols和elasticnet分别是51.3、51.3和51.2分，lasso是49.8分。

亮点2：稳健的异常值检测 – 3-Sigma法则

3-Sigma判别法 很经典，数学上：正态分布中， 3σ 外的概率只有 0.3%删除 1.95% ~ 1.75% 的数据，说明异常值极少质量很高：绝大多数数据是有效的保留高价值数据：不会误删真正的豪宅

亮点3:特征工程，先“加”再“减”

构建交互特征，基于变量之间的组合效应，构建了卫浴配比，套内使用率，小区品质等指标，讲特征数分别增加到82（房价），77个（租金）。最后，配套得分*地铁交互与小区品质成功进入特征重要性top20。

房价模型性能汇总：

Model	MAE_In_Sample	RMSE_In_Sample	MAE_Out_Sample	RMSE_Out_Sample	MAE_CV	RMSE_CV	R2_In_Sample	R2_Out_Sample	R2_CV
OLS	646466.279208	1.081084e+06	638831.460098	1.084221e+06	647063.583300	1.084265e+06	0.587291	0.564689	0.564655
Lasso	659344.561965	1.095554e+06	651103.633064	1.097443e+06	659784.404248	1.101245e+06	0.576168	0.554008	0.550913
Ridge	646466.277164	1.081084e+06	638831.473525	1.084222e+06	647063.581667	1.084265e+06	0.587291	0.564689	0.564655
ElasticNet	646938.571671	1.089729e+06	639703.787445	1.103863e+06	647563.371553	1.095661e+06	0.580664	0.548774	0.555455

租金模型性能汇总：

Model	MAE_In_Sample	RMSE_In_Sample	MAE_Out_Sample	RMSE_Out_Sample	MAE_CV	RMSE_CV	R2_In_Sample	R2_Out_Sample	R2_CV
OLS	157992.345242	252002.384746	155788.041937	249479.958664	158157.124337	252790.696607	0.601057	0.599095	0.588384
Lasso	161200.734592	256857.533881	158618.822258	253431.991171	161269.526095	256973.570411	0.585537	0.586293	0.574649
Ridge	157992.349381	252002.412256	155788.042724	249479.984987	158157.128671	252790.727660	0.601057	0.599095	0.588384
ElasticNet	158246.974514	253102.959075	155830.818372	250170.994724	158388.484324	253695.956616	0.597565	0.596871	0.585431

亮点1:地域相关性分析

地域相关性函数probabilistic hierarchy
validation, 我们的得到城市, 区县,板块的强烈
关系, 为删减变量提供了依据

kaggle score:

OLS 59.9

LASSO 58.2

Ridge 59.9

ElasticNet 59.0

Price:

亮点2: 更稳健的测试集处理

考虑到zscore标准化等方法需
要用到均值,用训练集的均值和
标准差对测试集标准化

Method	in sample	out of sample	CV	
OLS	0.2666	0.2715	0.2673	Best
LASSO	0.2724	0.2774	0.2727	
Ridge	0.2666	0.2715	0.2673	
ElasticNet	0.2692	0.2742	0.2696	
method:	MAE/mean(Y)			

亮点3: 异常值不局限与3-sigma

对数据做检验,不服从正态分布就用IQR方法
结合取对数和偏度的计算缓解IQR不足

Rent:	in sample	out	CV	
OLS	0.2735	0.2727	0.2739	Best
LASSO	0.2764	0.2761	0.2767	
Ridge	0.2735	0.2727	0.2739	
ElasticNet	0.2753	0.2748	0.2757	

KAGGLE:35.3

亮点一：根据实际情况数据清洗

重复的舍去、无关的去除、根据实际来处理变量（经纬度、房屋年限）

亮点二：特征工程层次化：从基础变换到交互特征

特征工程包含三个递进层次：
基础筛选：通过filter_numeric_features保留数值型特征，剔除除 ID 等无关变量；
单调变换：对正值值为面积 × 正的特征进行对数变换（log_前缀特征），缓解数据偏度；
交互特征：构建“卧室数x面积”“环线 × 交通得分”等业务相关交互项，捕捉变量间的协同效应。

反思：特征工程的局限性、代码分解调试

问题：当前特征工程以通用方法为主（如对数变换、简单交互项），缺乏针对“房价 / 租金”这类房地产数据的深度业务特征。例如：
未考虑“房龄”（建筑年代与当前时间的差值）、“人均面积”（面积 / 卧室数）等与居住舒适度直接相关的衍生特征；
对“环线_encoded”“交通得分”等地理属性特征，未结合区域均值（如“区域平均房价”“区域交通得分排名”）构建相对指标，丢失了位置溢价的关键信息；
未处理可能存在的多重共线性，可能影响线性模型的系数稳定性。

模型	样本内MAE	样本外MAE	交叉验证MAE
OLS	572031.34	570653.47	572474.70
Lasso	573141.31	571465.52	573561.13
Ridge	572052.36	570678.70	572499.14
ElasticNet	573895.49	571812.57	574304.79

房价最佳模型：OLS

租金模型性能：

模型	样本内MAE	样本外MAE	交叉验证MAE
OLS	52554.89	52633.60	52594.18
Lasso	53055.01	53161.24	53095.17
Ridge	52554.96	52633.68	52594.27
ElasticNet	54750.90	54998.31	54791.86

租金最佳模型：OLS