

马雨翔：模型简介



中國人民大學
RENMIN UNIVERSITY OF CHINA

- **项目思路：**数据清洗（单位、不规范命名、str to num） – 异常值处理 – 选择缺失不多的变量进行插值 – 特征工程（非线性项、选择重要变量） – 模型回归 – 模型校准
- **时间规划：**2/3数据清洗，1/3用于模型调试（始终相信trash in, trash out）。
- **辅助工具：**Copilot > GPT >> 腾讯元宝 ≈ KIMI（最后二者完全不适合进行代码撰写，过于冗杂、繁复，代码不够简洁明了且对prompt添加过多自己的理解）
- **模型创新：**保留数据、文本分析、
 - （1）数据处理细节到位。从one-hot处理、权重处理到文本分析，通过excel列表逐个处理变量，到缺失率筛选，再到连续变量填充，做到自我最好水平。最终保留变量170个（price）、74个（rent）
 - （2）尽量保存多的信息进行训练。体现为利用LLM生成词典，考虑客户反馈（更大权重）和房源描述生成综合评价，验证其分布尚可。
 - （3）摸透数据。利用Matplotlib画柱状图、箱线图和核密度图；利用missingno画缺失矩阵、缺失热力图。
- **训练结果：**price最优模型为OLS ($R^2=0.581$)，rent最优模型为LASSO ($\alpha=10$, $R^2=0.6391$)，Kaggle分数24.1。
- **自我评价：**尽己所能，还算满意。考虑到上课目的（1）学会怎么用python处理大规模数据；（2）了解大模型作用原理。本人不做机器学习，现在已经很满意了。

Price	训练集			测试集			6折交叉验证	
	MAE	RMSE	R^2	MAE	RMSE	R^2	MAE	RMSE
OLS	981566.22	1636521.52	0.581	979609.96	1619617.58	0.5972	982457.54	1639922.28
LASSO ($\alpha=100$)	981263.04	1636610.87	0.5809	979405.85	1619656.33	0.5972	982087.03	1639919.8
RIDGE ($\alpha=100$)	979475.61	1637382.35	0.5805	977323.09	1620202.3	0.5969	980101.49	1640770.09
ELASTICNET ($\alpha=0.01; l1 \text{ ratio}=0.7$)	978959.98	1639254.4	0.5796	976554.39	1621814.28	0.5961	979745.89	1642316.39

Rent	训练集			测试集			6折交叉验证	
	MAE	RMSE	R^2	MAE	RMSE	R^2	MAE	RMSE
OLS	217787.01	370154.54	0.6392	219921.05	395702.63	0.622	217997.13	370712.74
LASSO ($\alpha=10$)	217791.04	370214.8	0.6391	219923.23	395747.17	0.6219	217993.76	370766.14
RIDGE ($\alpha=1$)	217788.85	370163.59	0.6392	219944.01	395712.96	0.622	217995.63	370720.42
ELASTICNET ($\alpha=0.01; l1 \text{ ratio}=0.9$)	217816.25	370239.41	0.6391	219940.2	395761.33	0.6219	218016.44	370786.06