

Python Hackathon 结果汇报

*missing flag、区域平滑算法和模型*blending

汇报人：马雨翔

2025年12月25日

01 建模概览

建模思路 = 数据清洗：特征工程：模型调教 = 2：5：3

- 数据清洗 = (a) 格式、单位、范围中值处理; (b) 缺失pattern捕捉(共同缺失); (c) 删除object、常数列
- 数据处理 = (a) 预测变量变为log_建面均价; (b) log_建面均价区域平滑算法; (c) 调用LLM文本分析; (d) 建立missing flag(“别墅类型_缺失”); (e) 长尾业务逻辑、log修正; (f) 相关性、VIF剔除冗余变量; (g) 识别data leakage
- 模型调教 = XGBoost(未插值) – Feature Importance筛选变量再训练XGBoost_Slim – 业务逻辑 + [Iterative Imputer + XGBoost]双重插值 – XGBoost(插值版) – OLS – LASSO – ANN – 模型结果blending

模型相较期中的改进主要有如下3点：

- 清洗从分类到定序，解决“one-hot一大堆，信息反而更无效”的维度爆炸问题。针对装修质量等明显等级区分变量，直接映射为定序变量。
- 特征从放到收，解决“想保留信息越多→变量越多→信息越乱”的无效提取问题。期中使用156个变量进行预测，本次尽管添加缺失标记、大量特征工程，但使用变量仅70个左右。并且从新的LASSO预测效果来看，这一信息提取是极为有效的。
- 模型从训到调，实现“模型拟合数据，而非数据适配模型”根据场景调优的效果。针对数据大量缺失特征，利用XGBoost树模型对缺失值的良好适应训练;插值后再次训练XGBoost、ANN、OLS、LASSO等模型。

Table I: 模型表现汇总

	In sample RMSE	Out of sample RMSE	Change of RMSE	Cross-validation RMSE	Kaggle	Note
XGBoost1_GPU_5Fold_Slim_0.1_Threshold	0.0841	0.1139	0.0298	0.1137	77.1	未插值
XGBoost1_GPU_5Fold_Slim_0.1_Threshold_Fixed	(预测修复版)	(预测修复版)	(预测修复版)	(预测修复版)	77.0	
Final_Ensemble_Blending_Fixed	(预测修复版)	(预测修复版)	(预测修复版)	(预测修复版)	76.7	
ANN_V3_HighDim_Tanh_Explorer_Fixed	(预测修复版)	(预测修复版)	(预测修复版)	(预测修复版)	75.3	激活函数 = Tanh
ANN_V3_HighDim_Tanh_Explorer	0.0983	0.1324	0.0341	--	75.3	
LASSO_Rulingout_Model_Fixed	(预测修复版)	(预测修复版)	(预测修复版)	(预测修复版)	70.3	alpha = 0.000022
LASSO_Rulingout_Model	0.1524	0.2106	0.0582	(CV=5)	70.3	冗余变量1/84
OLS_5Fold_Model	(best_mid_term)	(best_mid_term)	(best_mid_term)	(best_mid_term)	24.3	期中最优

02 模型亮点

□ 在本次建模中，代码一共有三点创新：

□ 如果缺失也是一种信息？missing flag作为缺失标记



- 大量数据严重缺失，丢弃未免可惜 ⇒ missing flag标记变量缺失情况；
- 缺失竟然也有pattern ⇒ missing flag加总聚合为missing index标识共同缺失；
- 别墅类型的缺失可能指示房产不是别墅，这一信息一旦损失会造成长尾预测极大失效 ⇒ missing flag “别墅类型_缺失”标明“谁是别墅”。

□ 只能利用模型依靠非线性等强行拟合地理位置-房价关系？

- 直觉：如果使用模型强行拟合log_建面均价和城市、区域、板块之间的关系，模型构造非线性可能并不符合现实逻辑(相邻板块房价接近)。
- 思路：计算城市、区域、板块层面均值，利用贝叶斯平滑算法，从小到大依次根据板块-区域-城市-全局，计算平滑值geo_quality_importance。
- 这一算法有效保证即使面对训练集中没有的地理信息，也能平滑成功。

□ 基于算法特点模型blending

- 表现最优的XGBoost抓主要趋势，LASSO作为线性模型稳住预测底盘，ANN通过第一层1024维映射补充高维交互特征。
- 三个模型以0.7:0.2:0.1的比例直接在预测集上混合。
- 后续将尝试CV-search的Weight Blending，和外套模型的Stacking Blending。



02 模型亮点

□ 在本次建模中，代码一共有三点创新：

□ 如果缺失也是一种信息？missing flag作为缺失标记

- 大量数据严重缺失，丢弃未免可惜 ⇒ missing flag标记变量缺失情况；
- 缺失竟然也有pattern ⇒ missing flag加总聚合为missing index标识共同缺失；
- 别墅类型的缺失可能指示房产不是别墅，这一信息一旦损失会造成长尾预测极大失效 ⇒ missing flag “别墅类型_缺失”标明“谁是别墅”。

□ 只能利用模型依靠非线性等强行拟合地理位置-房价关系？

- 直觉：如果使用模型强行拟合log_建面均价和城市、区域、板块之间的关系，模型构造非线性可能并不符合现实逻辑(相邻板块房价接近)。
- 思路：计算城市、区域、板块层面均值，利用贝叶斯平滑算法，从小到大依次根据板块-区域-城市-全局，计算平滑值geo_quality_importance。
- 这一算法有效保证即使面对训练集中没有的地理信息，也能平滑成功。

□ 基于算法特点模型blending

- 表现最优的XGBoost抓主要趋势，LASSO作为线性模型稳住预测底盘，ANN通过第一层1024维映射补充高维交互特征。
- 三个模型以0.7 : 0.2 : 0.1的比例直接在预测集上混合。
- 后续将尝试CV-search的Weight Blending，和外套模型的Stacking Blending。

```
"""
层级平滑目标编码 (Hierarchical Target Encoding)
m: 平滑权重参数。m越大，越倾向于信任高层级(区域/城市)的均值。
"""

# 1. 计算全局均值 (作为最终保底值)
global_mean = df[target_col].mean()

# 2. 计算各层级的统计量 (均值和计数)
# 城市层级
city_stats = df.groupby('城市')[target_col].agg(['mean', 'count']).rename(
    columns={'mean': 'city_mean', 'count': 'city_count'})

# 区域层级
dist_stats = df.groupby('区域')[target_col].agg(['mean', 'count']).rename(
    columns={'mean': 'dist_mean', 'count': 'dist_count'})

# 板块层级
block_stats = df.groupby('板块')[target_col].agg(['mean', 'count']).rename(
    columns={'mean': 'block_mean', 'count': 'block_count'})

# 3. 合并统计量到主表
df = df.merge(city_stats, on='城市', how='left')
df = df.merge(dist_stats, on='区域', how='left')
df = df.merge(block_stats, on='板块', how='left')

# 4. 执行平滑逻辑 (Bayesian Smoothing 思想)
# 逻辑: 平滑后的值 = (本级总和 + 上级均值*m) / (本级计数 + m)

# 第一步: 用城市均值平滑区域均值
df['smoothed_dist_val'] = (df['dist_mean'] * df['dist_count'] + df['city_me

# 第二步: 用平滑后的区域均值再来平滑板块均值
# 这解决了“孤岛板块”只有1个样本时，其特征值会非常接近所属区域的平均水平
df['geo_quality_score'] = (df['block_mean'] * df['block_count'] + df['smoot
```

Table II: 区域平滑变量Feature Importance统计

geo_quality_score			
Gain(平均增益)	Cover(覆盖度)	Weight(分裂次数)	Importance_Share(%)
68.578392	10898.5	3925	45.5

02 模型亮点

□ 在本次建模中，代码一共有三点创新：

□ 如果缺失也是一种信息？missing flag作为缺失标记


- 大量数据严重缺失，丢弃未免可惜 $\Rightarrow$ missing flag标记变量缺失情况；
- 缺失竟然也有pattern $\Rightarrow$ missing flag加总聚合为missing index标识共同缺失；
- 别墅类型的缺失可能指示房产不是别墅，这一信息一旦损失会造成长尾预测极大失效 $\Rightarrow$ missing flag “别墅类型_缺失” 标明 “谁是别墅”。

□ 只能利用模型依靠非线性等强行拟合地理位置-房价关系？

- 直觉：如果使用模型强行拟合log_建面均价和城市、区域、板块之间的关系，模型构造非线性可能并不符合现实逻辑(相邻板块房价接近)。
- 思路：计算城市、区域、板块层面均值，利用贝叶斯平滑算法，从小到大依次根据板块-区域-城市-全局，计算平滑值geo_quality_importance。
- 这一算法有效保证即使面对训练集中没有的地理信息，也能平滑成功。

□ 基于算法特点的模型blending

- 表现最优的XGBoost抓主要趋势，LASSO作为线性模型稳住预测底盘，ANN通过第一层1024维映射补充高维交互特征。
- 三个模型以0.7:0.2:0.1的比例直接在预测集上混合。
- 后续将尝试CV-search的Weight Blending，和外套模型的Stacking Blending。



03 后记：AI时代，人的分工是什么？

- ❑ 当AI能够完成绝大多数代码的时候，人在编程中似乎已经无足轻重：没有AI会写代码、不会像AI不知疲倦、总会犯一些愚蠢的错误。而AI的表现更多是这样狼狈和窘迫的反面：它精准、高效、不知疲倦。在gemini3.0 pro出世后，更是可以下一个略带悲观的结论：**AI coding在绝大多数场景下，表现得比人类好得多得多。**
- ❑ 那人在编程中的工作是什么？编程会成为AI的工作么？换言之，人们会因为AI退出编程领域么？显然不会，否则今天也不会在这一堂python课。
- ❑ 从设计数据清洗到特征工程，再到模型训练，本次建模的思路全部来自于我。
 - 数据清洗中，我判断特征分类还是将他们按顺序映射，抑或是多类总结映射为几类；
 - 特征工程中，构造缺失标记的想法受启发于Dahl et al.(2020, QJE)处理RCT数据的思路；
 - 模型训练中，是我设计出“未插值数据 – XGBoost1 – 插值 – XGBoost2 – OLS – LASSO – ANN – 预测数据物理修复 – Blending”的思路。
- ❑ 这就像问“LDA提取文本主题和质性研究中扎根理论编码什么区别？”LDA依赖概率计算，而扎根理论吸纳更多现实知识。那么人和AI的关系可能也是如此，**人知道现实世界的错综复杂关系，AI有冷峻严密的计算逻辑，二者将以合作的姿态前行。**
- ❑ 毕竟，AI还没有智能到我可以直接把“ruc_Class25Q2_train_price.csv”和“ruc_Class25Q2_test_price.csv”丢给它，它就能自动写完全部模型的地步。不过想必到了那一天，答案就需要再商榷了。

谢谢！

汇报人：马雨翔

2025年12月25日