




中國人民大學
RENMIN UNIVERSITY OF CHINA


Artificial intelligence

人工智能与Python程序设计 期末项目汇报

李春 2022201794

2025 年 12 月 25 日





技术栈与运行环境

- 大模型应用: DeepSeek-V3 API (通过 aiohttp 实现高并发异步调用)
- 特征工程: Sklearn (LabelEncoder, StandardScaler), Jieba (中文分词)
- 计算加速: 支持 CUDA (NVIDIA GPU) 及 MPS (Mac Metal) 硬件加速
- 依赖库: Torch, LightGBM, XGBoost, Matplotlib/Seaborn

01 阶段一: 非结构化数据增强 (LLM-Based)

02 阶段二: 数据清洗 (Data Cleaning)

03 阶段三: 特征工程 (Feature Engineering)

04 阶段四: 建模与预测 (Modeling & Prediction)


■ 利用大语言模型 (DeepSeek-V3) 对文本字段进行语义理解与情感打分, 将非结构化信息转化为量化指标。

■ 构建通用清洗工具类 DataCleaner, 基于正则提取 (Regex) 处理面积、户型、楼层、费用等脏数据。

■ 构建板块价值基准 (Plate Pricing)、房龄计算、季节性特征及居住舒适度指标。

■ Ensemble Algorithm: Random Forest、Xgboost、LightGBM

■ Deep Learning: Pytorch ANN、CNN



引入 LLM 进行非结构化文本的情感与价值挖掘

任务统计:

总数据量: 34017

已完成: 7000 (跳过)

待处理: 27017

正在处理批次: 7000 - 7999 ...

100%|██████████| 1000/1000 [03:34<00:00, 4.65it/s]

进度已保存! 本批成功: 1000/1000

DeepSeek-V3

传统NLP方法（如TF-IDF）仅关注词频，缺乏语义理解。

本项目引入 DeepSeek-V3 大模型，模拟房地产分析师视角，对文本进行多维度打分。

多维度评分体系


- 情感评分：分析“客户反馈”字段，打分范围 $[-1, 1]$ 。
- 特定维度评分：针对“核心卖点”、“户型介绍”、“周边配套”、“交通出行”四个维度分别生成独立评分。

高性能工程实现

- 异步并发 (AsyncIO)：使用 aiohttp 和 asyncio 实现高并发请求 ($MAX_CONCURRENT=50$)，大幅提升处理数十万条数据的效率。
- 断点续传机制：设计 load_data_with_checkpoint 函数，支持任务中断后自动恢复，防止API调用失败导致的前功尽弃。
- 智能限流与重试：内置 RateLimiter 和指数退避重试机制，确保API调用的稳定性。

价值产出

- 将原本无法直接使用的长文本描述，转化为了模型可直接读取的数值型强特征 (Strong Features)。



特征工程、质量验证与建模



Alpha 特征构造

- 板块基准价 (Target Encoding 变体): 计算各板块 (Plate) 的平均单价作为基准特征, 捕捉地段价值 (这是房价预测中最强的特征之一)。
- 时间周期特征: 从交易时间中提取月份, 并构造“旺季/淡季”二值特征, 捕捉市场周期性波动。
- 居住属性衍生: 构造“平均房间面积”、“相对楼层位置”等衍生特征, 量化居住舒适度。

——“……非常激进, 不少明显对价格有影响的变量被直接删掉”

质量检查

- 通过verify_and_save_data函数自动检查关键指标。
- ✓ 负值检查: 确保无负房价。
- ✓ 相关性检查: 验证“面积”与“价格”的相关系数 (Log 变换后约为 0.49), 确保数据物理规律正确。

——IQR 把数值“压扁”、导致信息完全丢失

- 集成学习: 利用已安装的 LightGBM 和 XGBoost 进行树模型集成, 处理表格数据的非线性关系。
- 深度学习: 利用 PyTorch 构建神经网络, 进一步挖掘特征间的深层交互。
- 目标变换: 已对目标变量 Price 进行了 Log1p 变换, 使其更符合正态分布, 利于模型收敛。

Top 15 Feature Importances (Model-based):		
	feature	importance
42	predict_price_base	0.804451
40	plate_base_unit_price	0.076243
31	lon	0.018083
29	lat	0.016740
43	prop_fee	0.007953
3	city	0.006551
1	avg_room_size	0.006223
0	area	0.005238
11	floor_type	0.004519
10	floor_total	0.003605
9	floor_pos_ratio	0.003590
57	情感评分	0.003218
50	total_houses	0.002940
49	total_buildings	0.002512
56	开发商	0.002374

Task	Metrics	In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Score
Rent	Ridge	0.388	0.4048	0.3843	-8.21
Sale	Ridge	0.4561	0.4389	0.4528	
Rent	RF	0.0896	0.174	0.1724	75.7
Sale	RF	0.0815	0.1352	0.1387	
Rent	XGB	0.1565	0.1762	0.1746	75.6
Sale	XGB	0.125	0.1389	0.14	
Rent	LGBM	0.163	0.1774	0.176	75.5
Sale	LGBM	0.1296	0.1394	0.1398	
Rent	ANN	0.1895	0.1994	0.2073	71.8
Sale	ANN	0.1627	0.171	0.1828	
Rent	CNN	0.2312	0.2336	0.2437	68.4
Sale	CNN	0.2147	0.2188	0.2413	
Rent	Best Model	0.0896	0.174	0.1724	75.7
Sale	Best Model	0.0815	0.1352	0.1387	



中國人民大學
RENMIN UNIVERSITY OF CHINA

Artificial intelligence

人工智能与Python程序设计

敬请批评指正！

李春 2022201794

2025 年 12 月 25 日

