



一、数据处理与特征工程

靳沛峤 2022202683



中國人民大學
RENMIN UNIVERSITY OF CHINA

除常规清洗外，额外对“客户反馈”列进行了NLP处理：

- 输入、清洗、分句；
- 调用BAAI/bge-reranker-base模型进行方向识别与方面情感分析（相当于对每个分句embedding）；
- 每个方面输出4个数值：提及次数、平均情感、情感最差的分句、最强命中证据，把“长文本”变成低基数类别 + 固定维度数值特征，直接拼到结构化特征表里供 XGB/Stacking 使用。

原因：减轻污染、减轻不确定性、避免数据泄露

其他特征工程包括：

1. 两类地理特征处理：CityCenterDistanceTransformer到“城市中心”的距离：训练阶段用训练集按城市计算坐标均值作为“城市中心”，并用haversine算球面距离；KMeansGeoTransformer按城市分别坐标做MiniBatchKMeans聚类；k 会按城市样本量自适应。
2. 派生其他变量例如：面积log、每室面积、费用类log、每平米费用、套内面积、楼层位置ordinal编码等。



二、亮点

靳沛峤 2022202683



中國人民大學
RENMIN UNIVERSITY OF CHINA

1. Optuna+Nested CV+Early Stopping框架

A. Optuna: 采用贝叶斯优化在超参空间采样, 并使用中位数Pruner节省算力; 加入 `early_stopping_rounds`; B. Nested CV: 一边调参、一边用同一份 CV 分数来“评估模型好坏”, 会产生乐观偏差; 内层调参、外层评估的方式使得分数更接近真实泛化; C. Early Stopping: 对于训练集根据1:9划分valid, 用于确定`early_stopping_rounds`, 避免过拟合, 找到最佳迭代数。


2. ANN: 通过SVD降维后进行Linear+ReLU+Dropout的MLP回归, 先压缩再学习非线性组合, 能力更强; 同时避免参数量过大爆内存、训练速度过慢等问题; 加入Early Stopping, 减少过拟合。

3. Stacking:

a. Base Model: XGB、LGBM、Catboost (对每个模型做seed-bagging取均值)

b. Meta Model: Ridge

c. 为避免数据泄露, 在训练Meta时使用OOF, 将每个base的oof预测值作为Meta的训练值; 之后对全dev样本进行Base训练, 并用训练好的Meta预测holdout集和test集。





二、亮点

靳沛峤 2022202683



中國人民大學
RENMIN UNIVERSITY OF CHINA

d. 在划分折时使用city-stratifiedKfold，即保证每个折内的城市大致相同。

结果展示：

task	model	In sample rmse	Out of sample rmse	Cross-validation rmse	Nested CV rmse mean	Final train OOF rmse
price	RF	0.098006	0.157008	0.14826	NaN	NaN
	ANN	0.167308	0.211898	NaN	NaN	NaN
	XGB	0.167325	0.178336	0.120448	0.157056	NaN
	Stacking	0.112341	0.120764	0.115448	NaN	0.112341
rent	RF	0.124425	0.190747	0.182409	NaN	NaN
	ANN	0.178727	0.218717	NaN	NaN	NaN
	XGB	0.137317	0.181682	0.174359	0.191959	NaN
	Stacking	0.167446	0.175919	0.169631	NaN	0.167446

