

模型	in sample RMSE	out of sample RMSE	CV	Kaggle
xgboost	224475	485233	498665	74.2
LightGBM	266384	479343	501432	69.7

只有40行的数据清洗

数值型

楼层个别处理

时间

类别型

```
def clean_data(df):
    df = df.copy()

    # 提取数字
    def extract_num(x):
        if pd.isna(x): return np.nan
        res = re.findall(r"[-+]?[0-9]*\.?[0-9]+", str(x))
        return float(res[0]) if res else np.nan

    cols_to_extract = ['建筑面积', '套内面积', '建筑年代', '房屋总数', '楼栋总数', '物业费', '燃气费', '供热费', '停车费用']

    for col in cols_to_extract:
        df[col] = df[col].apply(extract_num)

    # 楼层
    rel_map = {'地下室': 0.0, '底': 0.1, '低': 0.3, '中': 0.5, '高': 0.7, '顶': 0.9}
    # 提取总楼层数
    df['总楼层数'] = df[floor_col].str.extract(r'共(\d+)层')[0].astype(float)
    # 提取相对楼层
    def map_rel(text):
        for k, v in rel_map.items():
            if k in str(text):
                return v
        return 0.5 # 默认中层
    df['相对楼层'] = df[floor_col].map(map_rel)

    # 时间处理
    df['交易年份'] = pd.to_datetime(df['交易时间'], errors='coerce').dt.year
    df['上次交易年份'] = pd.to_datetime(df['上次交易'], errors='coerce').dt.year

    # 丢弃文本信息过大/重复/处理过的列
    drop_cols = ['核心卖点', '户型介绍', '周边配套', '交通出行', '客户反馈', '物业办公电话', 'coord_x', 'coord_y', '环线位置',
                  '所在楼层', '交易时间', '上次交易']
    df = df.drop(columns=[c for c in drop_cols if c in df.columns])

    # 类别变量编码
    categorical_cols = df.select_dtypes(include=['object']).columns
    for col in categorical_cols:
        le = LabelEncoder()
        df[col] = le.fit_transform(df[col].astype(str))

    return df
```

