

指标表格：

Price	Train MAE	Test MAE	CV MAE	Kaggle
期中线性模型（OLS）	569,708	578,149	584,965	61.1
Random Forest	991,460	971,279	998,015	54.4
Lightgbm	165,849	245,103	252,953	76.1

Rent	Train MAE	Test MAE	CV MAE	Kaggle
期中线性模型（OLS）	150,333	152,420	154,536	61.1
Random Forest	232,297	230,947	234,190	54.4
Lightgbm	52,120	75,354	76,815	76.1

文本处理：

```
# 4. 向量化函数优化 (针对 CPU 提高 Batch Size)
def text_to_embedding(text_list, batch_size=40):
    all_embeddings = []
    # 使用 tqdm 监控进度
    pbar = tqdm(total=len(text_list), desc="RoBERTa Embedding")

    for i in range(0, len(text_list), batch_size):
        batch = text_list[i : i + batch_size]
        # 截断长度缩短到 64 以加速 CPU 计算
        inputs = tokenizer(batch, return_tensors="pt", padding=True,
                           truncation=True, max_length=64).to(device)

        with torch.no_grad():
            outputs = model(**inputs)
            # CPU 上 CLS 向量通常比 Mean Pooling 更快且效果稳定
            batch_emb = outputs.last_hidden_state[:, 0, :].cpu().numpy()
            all_embeddings.append(batch_emb)

        pbar.update(len(batch))
    pbar.close()
    return np.vstack(all_embeddings).astype('float32') # 转换为 float32 节省空间
```

1. 深度语义特征引擎 (Semantic Engine)

- 模型选型**：采用 **RoBERTa-WWM-Ext** 预训练模型，捕捉房源描述中“精装修”、“溢价空间”等深层语义。
- 架构优化**：提取 **CLS 核心向量**，在保持高阶语义表征的同时，针对实时推断场景进行了 CPU 端的计算加速。

2. 潜变量空间压缩 (Latent Space Compression)

- 降维策略**：利用 **Truncated SVD (奇异值分解)** 将 768 维语义向量压缩至 100 维。
- 创新价值**：有效过滤文本噪声并消除维度灾难，将语义信号与结构化特征完美融合，使 LightGBM 的预测精度提升了 **[X]**%。

建模：

```
# ----- 1) CV (带早停逻辑) -----  
for i, (tr_idx, val_idx) in enumerate(kf.split(X_train)):  
    # 确保数据索引正确  
    X_tr, X_val = X_train[tr_idx], X_train[val_idx]  
    y_tr, y_val = y_train.iloc[tr_idx], y_train.iloc[val_idx]  
  
    # 实例化新模型用于 CV  
    m = lgb.LGBMRegressor(**params)  
  
    m.fit(  
        X_tr, y_tr,  
        eval_set=[(X_val, y_val)],  
        eval_metric='mae',  
        callbacks=[  
            lgb.early_stopping(stopping_rounds=100),  
            lgb.log_evaluation(period=0)  
        ]  
    )
```

1. **五折交叉验证与早停机制** (5-Fold CV with Early Stopping) 评估逻辑：采用 5-Fold Cross-Validation 评估模型泛化能力，通过 Early Stopping 动态确定各折的最佳迭代轮数 (Best Iteration)，有效防止模型对噪声的过度拟合。参数稳健性：模型核心参数 (如 `learning_rate=0.01`, `reg_alpha`) 兼顾了学习深度与正则化强度，确保在对数价格空间下的 MAE 最小化。
2. **集成预测与全量重训** (Ensemble & Refit Strategy) 双轨验证：对比“CV 平均集成预测”与“全量数据重训单模型”的结果。利用 CV 获得的平均最佳步数进行 Refit，确保最终模型在生产环境中的一致性与稳定性。量化评价：评估指标涵盖对数空间与原始价格空间，全方位监控价格预测的绝对误差 (MAE)，确保模型在经济解释性上的准确度。