

第一组期中展示

组员：陈丽啦 章子航 李春 郑融奇

train_price				
Metrics	In-sample	Out-of-sample	Cross-validation	Kaggle Score
OLS	959,832.53	938,794.52	1,145,991.94	33.90
Ridge	959,832.53	938,794.52	1,145,991.94	33.90
Lasso	959,832.53	938,794.52	1,145,991.94	33.90
ElasticNet	959,832.53	938,794.52	1,145,991.94	33.60

train_rent				
Metrics	In-sample	Out-of-sample	Cross-validation	Kaggle Score
OLS	251,299.34	244,237.22	251,381.44	33.90
Ridge	251,299.36	244,237.23	251,381.45	33.90
Lasso	251,553.85	244,558.08	251,633.86	33.90
ElasticNet	253,005.24	246,179.01	253,083.29	33.60

数据预处理：

- 对区间值使用平均值填充，缺失值用中位数填补，异常值通过四分位数间距识别并使用中位数替代。
- 类别数据（如楼层、环线）使用编码方法转换为数值型。
- 对偏度大的特征（如房价、面积）进行了对数变换，使数据更符合正态分布。

特征选择：

- 使用**Lasso**回归通过交叉验证自动选择最优正则化参数 α （0.01），筛选出对房价预测影响较大的特征。

模型选择与调参：


- 结合**OLS**回归、**岭**回归、**Lasso**回归和**弹性网**回归四种线性模型，使用5折交叉验证自动调优超参数，寻找最佳模型配置。
- 通过计算平均绝对误差（MAE）评估模型表现。

结果：

- OLS、Ridge、Lasso回归模型在训练集、测试集和交叉验证中的表现接近，**ElasticNet**模型表现稍逊。

Metrics	In sample	out of sample	Cross-validation	Kaggle Score
OLS	963608.7721778344	973237.5196302938	964174.1126193341	24.4
LASSO	973237.5196302938	973173.3507281336	964088.3221113613	---
Ridge	963500.1465950666	973237.5196302938	964062.0389481025	---

R-squared:0.57-0.59



Price	建筑面积_数值	电梯数	户数	梯户比	绿化率_数值	容积率_数值	物业费_数值	燃气费_数值	临近地铁	房间总数	城市_1	城市_2	城市_3	城市_4	城市_5	城市_6	城市_7	城市_8	城市_9	城市_10	城市_11	是否共有产权	是否有电梯	是否是精装修	是否是简装	是否是毛坯
Price	建筑面积_数值	绿化率_数值	容积率_数值	物业费_数值	燃气费_数值	房间总数	城市_1	城市_2	城市_3	城市_4	城市_5	城市_6	城市_7	城市_8	城市_9	城市_10	城市_11	是否整租	是否有电梯	是否有燃气						

数据清洗步骤：

- 1.删除缺失率大于50%的列
- 2.删除与Price 完全不相关的量--物业电话， 物业公司名称（相关系数分析）
- 3.删除无法分析的列， 比如客户评价

数据预处理步骤：

- 1.对于可用数据进行正则化， 比如物业费（0.6-0.61元/月/㎡）提取为物业费_数值(0.605)。房屋户型（3室1厅1厨1卫）提取为卧室数（3）， 客厅数（1） 厨房数（1）， 卫生间数（1）， 总房间数（6）
- 2.对于部分数据进行虚拟变量处理,比如城市， 配备电梯（是否配备电梯）， 周边配套（是否临近地铁）， 产权描述（是否是共有产权）
- 3， 数据填充， 对于缺失量较少的列， 使用整体中位数填充， 对于缺失较多的列， 比如房间数， 使用其他无缺失的列去预测（比如用建筑面积去预测房间数， 然后进行填充， 为避免数据泄露， 用训练集训练然后填充整体数据的缺失）

建模：

- 1.使用ols， 去除vif较大的变量发现R方下降， 所以选择保留
- 2.使用ridge和lasso， 先对数据进行标准化（z-score),利用交叉验证寻找最优超参数， 带入模型与OLS差距不大。
- 3.Elastic Net同

Model	In Sample	Out of Sample	Cross-validation	Kaggle Score
OLS	0.4755	0.4573	0.4746	-26.88
LASSO	0.4736	0.4562	0.473	-22.34
Ridge	0.4561	0.4389	0.4528	-8.21
ElasticNet	0.4588	0.4414	0.4583	-10.07
Best (Ridge)	0.4561	0.4389	0.4528	-8.21

价格

指标	样本内	样本外	交叉验证	<u>Kaggle</u> 得分
OLS	1.148969e-09	529806.058011	685076.252034	-16.17
LASSO	6.576786e+03	622688.982060	903851.055469	-16.17
Ridge	9.203177e+04	350162.175127	458535.139447	-16.17
Elastic net	5.239403e+04	453938.454665	605727.033227	-16.17

租金

Metrics	In-sample	Out-of-sample	Cross-validation	<u>Kaggle</u> Score
OLS	81007.480143	122872.926450	91150.566869	-16.17
Lasso	80987.406166	87119.943507	86508.669949	-16.17
Ridge	80950.810483	87321.697875	86427.410333	-16.17
<u>ElasticNet</u>	80847.098382	87316.413706	86229.932431	-16.17

创新点：在数据处理时保留了大部分文本数据，使用snowNLP进行情感模型处理，将客户反馈数据化。

使用TF-IDF评估一个词在文档中的重要性，将文档转换为TF-IDF矩阵，并应用SVD进行降维。（SVD：用于降维，提取主要成分，减少特征数量。）

使用OOF防止数据泄露，在使用K折交叉验证时，数据集被分成K个部分（折），模型将在K-1个部分上训练，而在剩下的1个部分上进行验证。这个过程会重复K次，每次选择不同的部分作为验证集，并记录每次验证的预测结果。最终的OOF特征是基于K次验证的预测结果，这些预测结果不会在训练过程中被使用，从而防止了数据泄漏，为后续模型训练提供更有意义的特征。

谢谢！

组员：陈丽啦 章子航 李春 郑融奇