

HW4 Model Validation Report

Group 4 沈伯衡

2025 年 11 月 15 日

摘要

本报告对 Group 5 的代码和模型进行了全面检查，重点关注可复现性、数据处理流程与样本划分策略三方面。整体来看，模型思路清晰，但在外部文件管理、特征工程的重复处理，以及训练和验证样本的划分方式上，仍有一些会影响模型稳定性和可靠性的问题。针对这些情况，我们提出了三条改进建议：统一管理所有外部文件以保证流程可复现；搭建一个统一的特征工程 Pipeline 避免反复处理同一字段；以及将样本划分提前、确保预处理只在训练集上进行，从而避免信息泄漏。这些建议有助于提高模型的透明度、一致性，也让后续的调参和扩展更顺畅。

1 模型评估

1.1 可复现性

文件路径依赖本地，无法复现 代码中出现多次出现“ANN 房价预测结果 80bech.csv”，但由于并未附上该文件，导致后续无法复现

```
# ----- 1. 读取数据 -----  
# 读取ANN房价预测结果CSV（根据实际文件路径修改）  
ann_result_df = pd.read_csv("ANN房价预测结果80bech.csv", index_col=False) # index_col=False避免读取时多列索引
```

图 1: 并无该文件，后续无法复现

1.2 Data Processing Validation

多次对相同字段做 get dummies 填充，流程复杂度非常高 对“楼层、建筑类型、区域”等字段，多次补空值、重命名、再 dummy，一部分逻辑在前面，另一部分在后面，又有专门的 target_villa_types 处理。这类重复执行的处理，加入 Notebook 执行顺序不同，会导致特征数不同，进而导致模型不同。以下是一小部分示例：

```
# 1. 生成所有类别的独热编码（共6个虚拟变量）  
# prefix指定虚拟变量的前缀，方便区分  
floor = pd.get_dummies(df['所在楼层'], prefix='楼层', drop_first=True, dtype=int) %U 添加上下文到对话  
  
# 3. 删除原“所在楼层”列，合并虚拟变量到原数据框  
df = df.drop(columns=['所在楼层']).join(floor)  
  
floort = pd.get_dummies(df_test['所在楼层'], prefix='楼层', drop_first=True, dtype=int)
```

图 2

```
# 生成虚拟变量：为每个权属类型创建0/1列（prefix指定前缀，方便识别）  
dummft = pd.get_dummies(df_test['房屋用途'], prefix='用途', drop_first=True, dtype=int) %U 添加上下文到对话
```

图 3

```
# 生成虚拟变量：为每个权属类型创建0/1列（prefix指定前缀，方便识别）  
dummies = pd.get_dummies(df['交易权属'], prefix='权属', drop_first=True, dtype=int) %U 添加上下文到对话  
  
# 删除原始“交易权属”列，合并虚拟变量到原DataFrame
```

图 4

```
# ----- 原有虚拟变量生成逻辑 (不变) -----  
# 生成虚拟变量: 为每个权属类型创建0/1列 (prefix指定前缀, 方便识别)  
dummf = pd.get_dummies(df['房屋用途'], prefix='用途', drop_first=True, dtype=int) %U 添加上下文到对话
```

图 5

1.3 Sample choice

- 所有特征工程（文本 TF-IDF + SVD、哑变量、缺失值处理等）是在整个 df 上先做完，再划分 8:2 的。也就是说 X_test_split 这 20% 的“测试样本”，它的特征是用“包含自己”的整体统计量算出来的。严格意义上来说，这是预处理阶段对验证集信息轻微泄漏，但不算致命。

2 Suggestions

2.1 统一外部文件管理，保障完整可复现性

建议将所有外部文件进行统一管理，明确数据文件的存放路径、命名规则，并提供相应的执行脚本。同时附上复现清单，例如数据来源、代码版本与关键参数设置等。这样可以确保其他人在不同的环境中也能完整、顺利地复现模型的全部结果。

2.2 构建统一的特征工程 Pipeline，避免重复处理

建议使用统一的特征工程 Pipeline（如 sklearn 的 ColumnTransformer 或 Pipeline），把缺失值处理、编码、文本特征提取等步骤集中封装，并仅在训练集上进行 fit。这样可以确保每个字段只被处理一次，避免 notebook 多个 cell 的执行顺序对特征维度造成影响，同时保证测试集按照完全一致的流程进行 transform，避免 train 与 test 之间出现特征不对齐的问题。

这样做可以确保每个字段只被处理一次，避免 notebook 多 cell 执行顺序造成特征维度随机波动。同时可确保测试集严格执行 transform，不再出现 df 与 df_test 分别 dummy 造成的特征不一致问题。

2.3 调整样本划分流程：先划分，再预处理

建议将样本划分提前进行：首先将原始数据划分为训练集与验证集，然后仅在训练集上拟合所有预处理步骤，再将相同的处理流程应用到验证集与最终测试集。此方法可以避免特征工程阶段对验证集的信息泄漏，使验证误差更加真实地反映模型的泛化能力。