

Final Exam

XGBoost Pipeline & Relative Price Innovation

汇报人：沈伯衡 2022200859

2025 年 12 月 23 日


1. 整体管线：从多模态清洗到自动化评估

核心模块与代码逻辑证据：

- 多模态清洗：通过正则解析提取楼层比、装修及户型结构化指标，解决结构化文本。
- 地理位置感知：利用 K-means 基于经纬度生成 20 个空间组，采用 5-Fold OOF 方式估计组均值。
- 分流预处理：ColumnTransformer 实现数值 (Scaling)、类别 (One-Hot)、文本 (TF-IDF) 并行处理。
- 模型训练：利用 XGBoost 和 Keras 进行 5-fold CV，预测房价。

代码实现要点

XGBoost 参数配置: `learning_rate=0.02`,
`max_depth=10`, `min_child_weight=3`。





2. 模型评估结果与可解释性分析

(1) 交叉验证汇总 (5-Fold CV)

Metrics	In sample	Out sample	CV	Kaggle
Ridge	814,082	863,538	1,182,320	54.3
XGB	424,604	583,048	620,382	75.1
ANN	753,858	829,917	834,661	71.3

(2) 决策因子解释

- **空间主导性**: `cluster_mean_price` 显著高于其他变量，表明价格主要由空间层面的基准结构所决定。
- **面积**: `area` 在重要性排序中位居第二，表明房屋物理规模仍是影响价格的核心单体属性，但其作用建立在空间基准之上。



3. 创新点：相对价格 (Relative Price) 建模机制

核心思想：将“绝对水平”预测转换为“相对于局部参照系（组均值）的偏离”建模，以吸收空间异质性。

(1) 数学形式

目标构造：计算对数残差：

$$y_{rel} = \log(y_{absolute}) - \log(y_{cluster_mean})$$

反变换融合：映射回原尺度并融合：

$$\hat{y}_{final} = (1 - \alpha)\hat{y}_{base} + \alpha \cdot \exp(\hat{y}_{rel} + \log(y_{base}))$$

(2) 提分机制分析

- 消除异方差：价格绝对值跨度大，相对建模使噪声分布更均匀。
- 校准全局偏差：当 α 趋向 1 时，模型强制依赖组平均，有效缓解了基模型在极端价格区间的系统性漂移。

批判性思考

1. 泄露防范：组均值必须通过 OOF 统计，代码已通过 KFold 分折实现。
2. 尺度风险：过强的 α 可能导致预测值向均值“平滑”，需通过权重平衡单体特征与群体基准。

Kaggle 评分提升结果

当 $\alpha_{price} = 0.65$ 时，
相对价格融合模型将原模型得分
75.1 $\rightarrow$ 76.7

结论：该模块作为“校准器”显著增强了地理泛化能力。