

Final Exam Presentation

朱奕宁 2023200057



文本特征深度挖掘

01



LDA主题分析

- 对**核心卖点、户型介绍、周边配套、交通出行**这4个文本字段
- 提取**3个潜在主题特征**
- 将非结构化文本转化为可量化主题概率特征

02



LLM量化文本信息

- 综合房产描述文本
- 部署 **Qwen-0.5B 模型** 对**9个**关键维度进行标准化评分（交通便利、教育资源、医疗配套等）

03



情感分析量化

- 使用 **SnowNLP** 分析客户反馈列
- 生成**情感得分 (0-1)**
- 挖掘并量化潜在的客户主观信息



机器学习模型选择与优化

基础模型池

- Bagging 类模型:
RandomForest, ExtraTrees
- Boosting 类模型:
XGBoost, LightGBM,
CatBoost

模型堆叠融合

- Base models:
XGBoost + LightGBM +
CatBoost
- Meta model:
GradientBoostingRegressor
- 3折交叉验证生成元特征



结果展示

Metrics	In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Score
Midterm Linear Model	2457146.79	2090709.76	2442508.78	66.12
Random Forest	1056339.91	1197990.05	1285573.32	62.0
Extra Trees	1368781.6	1520348.46	1591406.33	52.6
XGBoost	440981.7	564292.72	629015	75.7
Light GBM	438891.83	546314.95	618283.3	76.2
Cat Boost	699135.05	723146.37	742866.38	73.2
Stacking	437621.95	541506.72	603009.14	75.9