



中國人民大學 財政金融學院
RENMIN UNIVERSITY OF CHINA | SCHOOL OF FINANCE

量化模型期末展示

韩方媛 2023200078



Models		In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Score
Lasso	price	0.20827	0.20862	0.20863	71.6
	rent	0.22542	0.2258	0.22581	
XGBoost	price	0.02285	0.1192	0.1192	77.9
	rent	0.07039	0.1677	0.16771	
LightGBM	price	0.07532	0.11999	0.11999	77.7
	rent	0.10466	0.16806	0.16807	
CatBoost	price	0.07985	0.11777	0.11777	77.6
	rent	0.11492	0.16771	0.16771	
ANN	price	0.1892	0.19871	0.20182	74.3
	rent	0.22311	0.23196	0.23455	
Ensemble	price	-	0.12178	0.12178	78.2
	rent	-	0.17032	0.17032	

NLP 文本特征挖掘

文本→RoBERTa Embedding→AE 降维→结构化特征

语义特征提取

- 模型选择：hfl/chinese-roberta-wwm-ext，哈工大讯飞实验室（HFL）针对中文优化，基于全词掩码（WWM）训练，更贴合中文分词
- 特征生成：均值池化输出 768 维原始语义特征

自编码器（AE）降维

- 模型架构：Encoder (768→64→16)，引入 Dropout (0.1) 防过拟合
- 输出特征：生成 16 维低维语义特征（列名：客户反馈_ae_0~15）

目标变量重构

- 将价格转化为 log1p(单位价格) ($\log(\text{Price}/\text{Area})$)，剔除面积共线性，修正右偏长尾分布

地理维度特征优化上


- 空间补全：基于经纬度 (lon,lat) 使用 KNN 算法填充 rent 数据集「区县 / 板块」缺失值
- 空间聚类：分城市动态 KMeans 生成地理聚类特征(Geo_Cluster)，捕捉地理聚集规律
- 目标编码：对地理类别（区域/板块/Geo_Cluster）执行「5折K-Fold+平滑项」目标编码
 - 训练集：分折计算类别均值+平滑，未见过类别填充全局均值，避免过拟合
 - 测试集：基于全量训练集计算平滑均值，杜绝数据泄露
 - 输出特征：生成「区域_TE/板块_TE/Geo_Cluster_TE」，将类别特征转化为可建模数值特征

无泄露缺失值填充

- 优先基于训练集计算板块统计量（众数/中位数）填充特征缺失值；
- 若板块全部空缺，采用全局统计量兜底

数值特征对数变换

- 针对非负数值列进行对数变换，降低特征偏度，捕捉相关性



- 模型：
 - GBDT 族群 (XGBoost, LightGBM, CatBoost)
 - 深度神经网络 (PyTorch ANN)
- XGBoost 核心模型与 Optuna 贝叶斯优化
 - 核心地位： 选取树模型中表现最佳的 XGBoost 作为基石模型。
 - 动态调优： 摒弃传统网格搜索，引入 Optuna 框架进行贝叶斯优化。通过15轮迭代精准锁定全局最优超参（如 learning_rate, reg_lambda），在偏差与方差间取得最佳平衡。
 - 严谨验证： 构建5折交叉验证体系，结合 Early Stopping 策略，确保验证集分布独立且有效防止过拟合。
- PyTorch 深度神经网络 (ANN)
 - 架构互补： 为了捕捉树模型难以拟合的复杂非线性特征，构建基于 PyTorch 的全连接神经网络 (MLP)，实现与 GBDT 的差异化互补。
 - 批归一化 (Batch Normalization): 在隐藏层引入 BN 层，加速模型收敛并缓解梯度消失问题。
 - 抗过拟合 (Dropout): 引入动态随机失活策略 (Rate 0.2-0.3)，增强模型在未见数据上的泛化能力。

- 动态加权集成模型
 - 多模型优势融合： 集成XGBoost、LightGBM、CatBoost、ANN四大模型，互补各模型特性。
 - 自适应权重分配： 基于各模型CV-RMSE倒数动态计算权重，让高性能模型贡献更大权重逻辑：模型误差越低，权重占比越高。

$$W_i \propto \frac{1}{CV_RMSE_i}$$
 - 结果突破： 集成后的模型kaggle score最高，达到了78.2（历史最佳）。

Models		In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Score
Lasso	price	0.20827	0.20862	0.20863	71.6
	rent	0.22542	0.2258	0.22581	
XGBoost	price	0.02285	0.1192	0.1192	77.9
	rent	0.07039	0.1677	0.16771	
LightGBM	price	0.07532	0.11999	0.11999	77.7
	rent	0.10466	0.16806	0.16807	
CatBoost	price	0.07985	0.11777	0.11777	77.6
	rent	0.11492	0.16771	0.16771	
ANN	price	0.1892	0.19871	0.20182	74.3
	rent	0.22311	0.23196	0.23455	
Ensemble	price	-	0.12178	0.12178	78.2
	rent	-	0.17032	0.17032	

因子分析

韩方媛 2023200078

特征工程有效性验证



- Target Encoding 主导：板块_TE 与 Geo_Cluster 包揽 Importance Top 3，证明引入先验信息的编码策略显著优于传统 One-Hot。
- 解决稀疏性：有效解决了高基数地理维度的稀疏问题，极大提升了模型的信息提取效率。

单价模型特性捕捉

- 解耦共线性：成功剥离了“面积”与“总价”的强相关性，area 在模型中不再是绝对主导。
- 规模负效应：识别出 area 呈现微弱负相关，精准捕捉到了“面积折价”现象，即小户型单价更高，完美契合预测 Unit Price 的目标。

经济学逻辑验证

- 品质溢价：“物业费”与“有电梯”在 SHAP 中呈显著正相关，验证了“高维护成本=高资产价值”的品质逻辑。
- 物理折旧：“房龄”呈现明确的负相关，模型量化了存量房市场中因物理老化带来的价值减损。



Partial Dependence Plot (Top 3 Features)

