



中國人民大學

RENMIN UNIVERSITY OF CHINA

Price & rent prediction model

The second group

實事求是

赵芳誉

日期：2025年12月25日



➤ 模型结构

原始特征 + 时序特征 + 文本 IDF → CatBoost / LightGBM

➤ 目标变量的对数变换

代码对应: `y = safe_log_transform(...)`。

讲稿话术（技术亮点）：“这是回归任务中的关键技巧。房价和租金数据通常呈‘长尾分布’（大部分便宜，少量极贵）。

直接预测原始价格会导致模型被豪宅数据带偏。

我采用了 Log1p 变换，将目标变量拉伸为近似正态分布（Normal Distribution）。这不仅加速了梯度下降的收敛，更显著降低了 RMSE 误差。”

语义特征优化（IDF 替代 BERT）

在计算资源受限条件下，采用 IDF 进行轻量化文本编码

保留语义区分度的同时，大幅提升训练与推理效率，将稀疏的文本数据压缩为 10 个高密度的数值特征，有效捕捉了房屋描述中的潜在语义（如“精装修”、“近地铁”带来的溢价）。





➤ Temporal Shift (时间分布偏移)

单纯依赖房屋本身属性是不够的，我们必须捕捉随时间变化的市场趋势（如通胀、房价普涨普跌）。应对策略：基于这个发现，我在特征工程中特意构造了 `trans_vintage`（距离首次交易天数）这一特征，用来显式地让模型学习时间趋势，从而保证在未来时间段的预测稳定性。”


特征分布一致性 - 以 `dist_center` 为例

Feature Importance (LGBM)
特征重要性



--- Feature Importance (LGBM) ---

<Figure size 720x360 with 0 Axes>





➤ Data Vintage (数据跨度处理)

- 面向非平稳环境，通过时间窗口与时间加权刻画市场漂移

我没有简单地使用“年份”作为分类特征，而是构建了一个连续变量 `trans_vintage`。定义：每一笔交易距离数据集中“最早交易日”的天数。作用：这将离散的时间点转化为了线性的时间距离。模型（特别是回归树）可以利用这个数值，极其敏锐地捕捉到房价随时间推移的整体上涨趋势（通胀）或短期波动（政策调控）。

- 在 Cell 3 中，我同时构建了两个看似矛盾但互补的特征：特征 A: `house_age` (房龄 = 交易年 - 建筑年) 代表逻辑：物理折旧。房子越老，设施越旧，通常对价格是负面影响。
- 特征 B: `trans_vintage` (交易时序) 代表逻辑：市场增值。交易时间越靠后，市场水位越高，通常对价格是正面影响。

MAE	Price/Rent	In sample	out of sample	Cross-validation	Kaggle Score
OLS	Price	627,809	631,630	633,062	61.6
	Rent	188,084	192,153	189,677	
LightGBM	Price	306214	465417	456,405	73.6
	Rent	128943	182033	250,106	
CatBoost	Price	559057	564706	543,068	67.6
	Rent	182955	212633	259,810	
Best_Ensemble	Price	411158	486356	453917	73.6
	Rent	151513	192881	182033	