



Natural Language Process:

1. 将不同列的所有文本信息加上标签以后，合并为一列“文本信息”
2. Hugging Face加载大模型BAAI/bge-small-zh-v1.5（北京智源人工智能研究院的Embedding Model）
3. 使用jieba 分词后的所有训练集文本信息，对 Model 进行 TSDAE 微调，使其更加适应房产语料（del_ratio=0.6）
4. 使用 Gemini 对 Price 和 Rent 的 2000 条数据分别进行打分，作为标签数据，将 BERT 头换为回归头预测并学习打分
5. 使用训练好的专家模型分别对 Price 和 Rent 进行打分预测
6. 同时将中间的语义向量 CLS 使用 AutoEncoder 从 512 维压缩到 16 维（使用GELU， CosineMSELoss， 加入部分噪声）


Feature Engineering:

1. 对类别特征生成 Target Encoding 的新特征
(中位数、平均数)
2. 将 LightGM 预测中重要性排名前300 的叶节点索引作为新特征，来捕捉复杂的非线性特征（Leaf Encoding 生成稀疏数据）



Modeling:

1. 使用 LightGM, RandomForest 作为基础的树模型预测算法, 使用 Optuna 自动调参
2. 使用 xFRM 作为一种核方法, 根据梯度变化, 调整特征空间中的维度, 使得相似的样本更加密集
github 库调用+手动修复补丁 (抽样计算神经网络+SVD 分解的Tikhonov 正则化)
3. 使用 TabM 模型 (2025ICLR 的 SOTA 算法)
 - a. 将数字特征分箱后嵌入 (向量化)
 - b. 批量集成32 个模型, 分别使用不同权重参数, 将所有模型的预测结果取均值作为输出结果
4. 使用 FT-transformer 算法作为另外一个深度学习算法的补充
 - a. 再次将数值特征分箱后与类别特征共同向量化
 - b. 使用自注意力机制学习特征与特征之间的动态交互
 - c. 最后将CLS Token通过一个线性层输出
5. 尝试如 DeepFM、TabFPN等其他算法 (最终未实现)



Result Stacking:

1. 使用前面数据训练的 Out-of-Fold 数据
2. 使用手动加权平均、Ridge, Scipy 中的Nelder-Mead算法进行 stacking
3. 选取 CV MAE 最小的结果作为最终结果

Metrics		In sample	Out of sample	Cross-validation	Kaggle score
OLS	Sales	349,859	347,307	353,300	74.14
	Rent	89,231	90,369	90,431	
LightGM	Sales	505,194	499,899	208,238	77.1
	Rent	125,104	123,339	67,018	
RandomForest	Sales	83,568	245,592	238,467	76.7
	Rent	32,381	70,412	71,993	
xFRM	Sales	231,241	231,452	251,351	76.1
	Rent	71,568	72,346	72,256	
TabM	Sales	214,452	235,614	234,374	73.8
	Rent	63,156	71,351	73,358	
FT-Transformer	Sales	211,678	213,451	225,863	74.4
	Rent	61,357	73,341	75,473	
Stacking	Sales	173,538	198,473	195,470	77.3
	Rent	41,356	65,357	64,057	