

房地产量化建模期末展示

黄鑫

2023200098

特征工程

■ 数值型及类别型特征

➤ 1.地理中心与经济中心互补

第一，物理维度：计算房源到城市几何中心的距离，衡量通勤半径。

第二，经济维度：针对每个城市，我通过自适应聚类锁定了Top3的高价板块，定义为“价值高地”，计算房源到这些高地的哈弗辛距离。

➤ 2.引入金融衍生因子

构建了板块溢价率，即“板块均价除以城市均价”。直接捕捉该区域相对于整个城市的溢价情况。溢价比较高的往往就是普遍高档小区的板块。

➤ 3.KNN物理插补以及其他地理特征

对于缺失数据，基于空间坐标进行了KNN物理插补，还原地理真实性；在每个城市内进行kmeans聚类；对城市、区域、板块进行Kfold目标编码。

➤ 4.目标变量重构：使用 $\log(\text{Price}/\text{Area})$ 作为目标变量。剔除面积共线性。

■ 文本特征

➤ 1.拼接构建完整上下文文本

【核心卖点】、【户型介绍】、【周边配套】三列拼接成为了full_Description列，让BERT模型能够看到更长的上下文；

【客户反馈】列因语境特殊，单独处理。


➤ 2.使用预训练bert模型

加载bert-base-chinese预训练模型，提取[CLS]Token的768维向量，实现了上下文感知嵌入。精准理解同一个词在不同语境下的差异。

➤ 3.Autoencoder降维

构建Autoencoder神经网络(768->128->16)。

提炼出对定价最关键的16个因子。



指标		样本内RMSE	样本外RMSE	交叉验证RMSE	Kaggle分数
Catboost	price	0.03842	0.11103	0.11103	78.0
	rent	0.08956	0.16308	0.1631	
Xgboost	price	0.06905	0.11208	0.11207	77.9
	rent	0.10373	0.16282	0.16281	
Mlp	price	0.10179	0.15186	0.15184	76.7
	rent	0.16793	0.19591	0.19581	
Lightgbm	price	0.06784	0.11333	0.11332	77.8
	rent	0.10308	0.16362	0.16361	
ridge	price	0.21273	0.21303	0.21302	71.1
	rent	0.23365	0.23396	0.23396	
stacking	price	0.11015	0.11019	0.11019	78.1
	rent	0.16189	0.16191	0.16191	

模型架构

■ 模型：Catboost,Xgboost,LightGBM,MLP,Ridge

➤ 1.差异化特征工程

针对算法归纳偏好定制输入数据特征。

CatBoost：传入原始字符串特征，利用其原生的**Ordered Target Statistics**处理高基数类别，避免One-Hot带来的维度问题。

MLP：实施严格的Log1p变换与RobustScaler标准化，适应神经网络对数值分布的敏感性。

XGBoost、LGBM：用Label Encoding保持树分裂的效率。

➤ 2.高效贝叶斯优化剪枝

基于Optuna框架进行超参数搜索，在Trial早期，若模型Loss差于历史中位数，直接终止训练。加快调参进程。

➤ 3.MLP深度算法调优学习率


针对MLP引入余弦退火热重启。让学习率周期性重置，帮助模型跳出局部最优，寻找泛化性更好的平坦极小值。

➤ 4.稳健的元学习器RidgeCV

第二层Meta-Model选用带L2正则化的RidgeCV。解决强基模型之间通常存在的多重共线性问题，防止对OOF数据过拟合，平衡偏差与方差。

➤ 5.分段残差诊断

进行分段诊断机制，重点考察豪宅与低价房的区间。经检验，模型在极端价格区间也没有出现明显的发散现象。证明Stacking后无显著系统性偏差。



指标		样本内RMSE	样本外RMSE	交叉验证RMSE	Kaggle分数
Catboost	price	0.03842	0.11103	0.11103	78.0
	rent	0.08956	0.16308	0.1631	
Xgboost	price	0.06905	0.11208	0.11207	77.9
	rent	0.10373	0.16282	0.16281	
Mlp	price	0.10179	0.15186	0.15184	76.7
	rent	0.16793	0.19591	0.19581	
Lightgbm	price	0.06784	0.11333	0.11332	77.8
	rent	0.10308	0.16362	0.16361	
ridge	price	0.21273	0.21303	0.21302	71.1
	rent	0.23365	0.23396	0.23396	
stacking	price	0.11015	0.11019	0.11019	78.1
	rent	0.16189	0.16191	0.16191	

模型分析



➤ Stacking模型贡献度分解

CatBoost作为核心基模型，贡献超50%的预测能力；XGBoost与LightGBM作为较好的补充；Ridge元学习器有效整合并稳定了所有模型的输出，最终集成模型取得了最佳Kaggle分数（78.1）。

➤ 特征重要性shap图

用于解释各特征如何影响预测结果。特征按重要性自上而下排列，分析可知，“板块TE”和“Geo_Cluster_TE”是影响力最大的特征，而“面积”与“log物业费”等也显著影响租金预测。


Stacking Model Contribution (PRICE)



➤ 边际效应分析

展示了TOP3特征对预测结果的独立影响趋势。“板块TE”和“Geo_Cluster_TE”与房价呈正相关，而“面积”增大则单位价值降低，符合经济学直觉。

Partial Dependence Plot (Marginal Effect)



Thanks!