


期末汇报

魏旒 2023200117

数据处理——特征构造

- 地区房产价格指数
 - 灵感1：真实情境中的房产价格预测，不是只根据非房价的其他房产特征来预测的，同一个街道/地区的房屋单价往往相近，是重要指标。
 - 灵感2：文本分析中，一个词的语义往往需要加上contextual meaning（其他词向量的加权）。在房价预测模型中，或许可以不把样本视为孤立的，它们也可以相互作用（构造跨样本的特征）。
 - 做法：基于lon、lat经纬度信息做KNN，找到距离最近的k处房产，用距离的倒数加权它们的房屋单价（Price/Area），得到新特征“地区房产价格指数（weighted_region_price_index）”。
 - 细节处理：
 - 避免Data leakage问题：将总训练数据划分为3个部分：ref_data、train_data、val_data，其中ref_data作为已知价格房产，用于为train_data、val_data、test_data提供地区房产价格参考。train_data、val_data、test_data仍为常规的训练集、验证集、测试集。
 - ref_data、train_data、val_data的数据分布是否一致：若不一致，在构造地区房产价格指数时会引入较大偏误
 - 房产距离过小或甚至为0，会导致距离倒数加权方法出现问题：引入微小偏移量 $\epsilon = 1e-8$



数据处理——自然语言



- 自然语言特征结构化（核心卖点、户型介绍、周边配套、交通出行、客户反馈）

- 提取核心关键词哑变量（若存在该关键词为1，不存在为0）

```
keyword_dict = {  
    '核心卖点': ['南北通透', '采光', '阳光', '视野', '诚心', '安静', '方便', '便利'],  
    '周边配套': ['医院', '公园', '商圈', '配套', '成熟', '购物', '娱乐', '休闲', '银行', '商场', '广场', '超市', '餐馆', '市场'],  
    '交通出行': ['地铁', '公交', '网络', '方便', '便利', '完善', '配套']  
}
```

- 合并所有自然语言特征为一段文本，调用“voidful/albert_chinese_tiny”预训练模型，获得文本语义向量（[CLS]的向量）

- 模型选择原因：大小合适（33.3MB），向量维度合适（312） 缺陷：没有针对房屋领域进行微调
- 文本语义向量的维数仍然太多：原有的特征维度约为200；增大模型训练开销和复杂
 - 解决方法：PCA降维，通过肘法自动选择降维后维数（保留90%方差的维度）



- 调用“voidful/albert_chinese_small_sentiment”预训练模型，对“客户反馈”进行情感分析打分

模型训练

- 神经网络提取高阶特征：shallow feature -> deep feature，捕捉特征之间复杂的相互协同作用

# 神经网络结构		param_grid = {			
self.model = torch.nn.Sequential(	Metrics	Type	In sample	Out of sample	Cross validation
nn.Linear(input_dim, hidden_dim_1),	Mid-term	Sales	0.1988	0.2006	0.1996
nn.ReLU(),		Rent	0.2282	0.2277	0.2288
nn.Linear(hidden_dim_1, hidden_dim_2),	LightGBM	Sales	0.0440	0.0888	0.0904
nn.ReLU(),		Rent	0.0553	0.1134	0.1139
nn.Linear(hidden_dim_2, feature_dim)	# 特征提取层	Sales	0.0180	0.0851	0.0874
nn.ReLU(),		Rent	0.0218	0.1121	0.1129
nn.Linear(feature_dim))	XGBoost				
)					
# 特征提取部分		'XGBoost': {			
self.feature_extractor	LightGBM:	XGBoost:			
nn.Linear(input_dim, hidden_dim_1),	learning_rate: 0.1	learning_rate: 0.05			
nn.ReLU(),	n_estimators: 600	max_depth: 10			
nn.Linear(hidden_dim_1, hidden_dim_2),	num_leaves: 63	n_estimators: 600			
nn.ReLU(),	reg_lambda: 1	reg_lambda: 0.1			
nn.Linear(hidden_dim_2, feature_dim)	subsample: 0.9	subsample: 0.9			
nn.ReLU(),					
)					

- GridSearchCV训练/调优LightGBM/XGBoost模型（shallow feature + deep feature）