

融合 NLP 与深度集成学习的房价预测模型


人工智能与 Python 程序设计期末展示

白博之 (学号: 2023200130)

Team Name: Boom0130

12 月 25 日

数据工程：自然语言与地理信息处理




NLP 处理“客户反馈”

利用 BERT 提取文本语义，并通过 Autoencoder 降维，捕捉“采光”、“噪音”等隐性价值。

地理信息处理策略

首创“板块->区域->城市”层级回退填充，并利用“邻居平滑”解决测试集板块未知的情况。

模型架构: Tri-Model Stack



模型核心点




- ▶ **特征工程**
BERT+Autoencoder
- ▶ **优势互补**
结合了梯度提升树 (GBDT: CatBoost/LGBM) 的结构化数据挖掘能力与深度学习 (ResNet) 的非线性特征提取能力。
- ▶ **Auto-Tuning**
引入 Optuna 自动超参数优化框架, 在交叉验证基础上提升模型的 Out-of-sample 泛化能力。
- ▶ **Stacking**
以 Ridge 回归作为元学习器, 学习不同模型的最优融合权重。
- ▶ **可解释性**
通过 SHAP 归因分析与偏依赖图量化关键特征的边际效应。

结果展示

表: 不同模型评估指标对比

模型	训练集 RMSE	测试集 RMSE	交叉验证 RMSE	得分
OLS	320582.07	319596.14	328584.51	72.3
CatBoost	267846.01	520147.69	549079.10	76.0
LightGBM	113509.78	577339.59	619515.16	75.2
ANN	489513.51	564392.17	648628.73	74.8
Tri-Model Stack	523849.64	505873.95	522335.10	76.3
Best Model	523849.64	505873.95	522335.10	76.3

模型	训练集 RMSE	测试集 RMSE	交叉验证 RMSE	得分
OLS	85179.74	88370.71	87848.58	72.3
CatBoost	90192.78	190910.06	179503.08	76.0
LightGBM	90276.13	203243.52	188159.05	75.2
ANN	165322.68	185156.85	203953.48	74.8
Tri-Model Stack	172006.25	184496.09	172039.45	76.3
Best Model	172006.25	184496.09	172039.45	76.3



Thank You!

Team Boom0130

敬请批评指正!