

01

数据清洗与类别变量建模

非互斥类别变量的 multi-hot 编码

房屋朝向、用途、建筑结构、供水/供暖等

保留复合语义（如“南北通透”“集中供暖+自供暖+无供暖”）

02

变量创新：政策周期

房改前（<1998）、黄金十年（1998-2007）、四万亿刺激期（2008-2010）、限购期（2011-2014）、去库存（2015-2016）、房住不炒（≥2017）

03

空间建模

基于经纬度推断城市中心点

使用球面距离（Haversine）计算真实空间距离，填充环线

04

开发商/物业公司：规范化+地理分层+TF-IDF→PCA→KMeans聚类编码

- (1) 对开发商与物业公司名称进行中文清洗、去噪与重复语义消解，减少虚假类别，提高代码效率
- (2) 基于跨城市开发商出现频率，将开发商划分为 local / multi_city / national 三个层级
- (3) 在同一地理层级内，使用 TF-IDF → PCA → KMeans 对主体进行聚类编码

05

客户反馈情感分析

- (1) 使用预训练中文情感模型 (Erlangshen-Roberta)
- (2) 结合业务词典微调 (如“位置、价格、环境、设施”等维度)
- (3) 引入否定词与程度副词 (如“非常”“不”) 进行情感修正
- (4) 最终得分 = 模型分 (55%) + 方面分 (35%) + 词典分 (10%)
- (5) 支持缓存机制，避免重复计算

06

分层插值

根据地理层级板块-区域-城市顺序进行分层插值

模型构建

01

时间和地理特征自动编码器



对线性模型、树模型和神经网络模型设计差异化的编码策略

- (1) 线性模型：直接数值 + dummy
- (2) 树模型：保持离散结构
- (3) 神经网络：时间特征提供正弦余弦周期和嵌套式编码；地理层级采用嵌套式编码

02

特征重要性差异化设计

- (1) 线性模型：回归系数
- (2) 树模型：gain & shap & shap dependence
- (3) 神经网络:Permutation Importance



模型	预测类别	In Sample	Out Sample	Cross Validation	Kaggle
OLS	房价	1, 004, 379	1, 051, 451	1, 015, 284	54. 2
	租价	337, 033	351, 112	339, 463	
Ridge	房价	1, 004, 384	1, 051, 096	1, 015, 124	57. 5
	租价	337, 139	351, 307	339, 587	
Lasso	房价	1, 005, 115	1, 047, 293	1, 014, 008	58. 7
	租价	339, 659	355, 463	342, 596	
XGboos t	房价	298, 480	444, 504	418, 903	75. 6
	租价	96, 366	144, 495	142, 436	
ANN	房价	1, 128, 339	1, 151, 155	1282105. 30	66. 1
	租价	377, 413	374, 988	354, 566	