

“客户反馈” NLP 特征工程

1. 基于相关性的初步筛选

```
corr_matrix = X_train.corrwith(y_train).abs()  
high_corr_features = corr_matrix[corr_matrix > 0.1].index.tolist()
```

jieba
分词

SnowNLP

计算情感得分与标签（积极/中性/消极）

情感得分
平均TF-IDF分


特征筛选

文本特征与目标变量
相关性 < 0.1
没有进入最终的模型
训练

TF-IDF

提取 top-5 关键词 + 平均TF-IDF分

可视化



整句
语义



StructBERT情感分类-中文-通用-base

iic / nlp_structbert_sentiment-classification_chinese-base

文本分类 情感分析 PyTorch 开源协议: Apache License 2.0

@通义实验室 提供 535,810下载 409,31MB 2024-01-08更新

尝试用StructBERT进行情感评分（positive概率软输出）

何宣晓

2023200184

第1页

建模

输入特征
↓
训练模型+评估
[LightGBM]
[XGBoost]
[CatBoost]
↓
加权融合



Ensemble:根据测试集MAE的倒数分配权重，集成三种模型

```
mae = result['out_sample_mae']  
# 使用MAE的倒数作为权重（性能越好，权重越大）  
weight = 1 / mae if mae > 0 else 1  
weights[result['model_name']] = weight  
total_inverse_mae += weight
```

设置早停防过拟合：连续50轮MAE无改善则终止

XGBoost调参：random_search

Feature
importance



模型评估

Model	In sample MAE	Out of sample MAE	CV MAE	Kaggle Score
LASSO	681097.09	736198.77	681424.62	53.97
	139785.03	256078.22	139878.98	

Model	In sample MAE	Out of sample MAE	CV MAE	Kaggle Score
XGBoost_Basic	228459.99	255794.18	260983.85	73.9
	62789.28	73549.31	72563.17	
RandomForest_Basic	492005.02	500867.38	510753.64	61.9
	112681.24	115834.34	117784.44	
XGBoost_Tuned	139205.47	214924.39	220736.96	75.6
	54899.10	70794.59	69492.64	
LightGBM_Optimized	234428.95	256708.56	262690.16	73.5
	63479.50	72373.79	72141.63	
CatBoost_Optimized	263754.96	283108.74	288788.64	72.9
	67115.93	74542.86	73957.84	
Ensemble_Weighted	196205.81	236538.47	236538.47	74.6
	60607.37	71282.51	71282.51	