

第14周

期中后的反思

更优质的数据处理

- 1 更精细的数据处理：将“朝向”特征规则化；适配多格式的“房屋户型”列正则匹配……
- 2 放弃粗糙的全局中位数填充，按区域/区县-城市-全局对数值特征进行中位数填充，对分类特征进行众数填充

受启发的特征工程

- 1 使用Kmeans方法，基于lon 和 lat为每个城市计算地理聚类
- 2 引入交叉特征：预测房价时引入每个板块的租金均价，预测租金时引入每个板块的房价均价
- 3 根据经济学意义组合非线性特征：①得房率=套内面积/建筑面积、②小区楼栋密度=小区总楼栋数/总户数、③居住环境质量=绿化率 × 容积率、④时间价值=房龄平方 ④……

第15周

LLM的尝试

Ollama本地部署

轻量模型
效果差复杂模型
缺GPU

模型未部署在GPU

工作区存储限额

Ollama云端部署

Ollama云端模型调用

效果好但
速度慢

第15周

复杂模型的尝试

LGBM模型

城市、区域、板块是高基数特征

1

高维特征难题：将用于线性模型的数据集直接输入

获取高基数特征的列索引（替代列名，避免匹配错误）

high_card_indices = [X_train_processed.columns.get_loc(col) for col in high_card_cat]

2

通过列索引将高基数特征列直接传入LGBM模型

神经网络模型

```
'verbose': 0, # 关闭默认日志  
'categorical_feature': high_card_indices, # 改用列索引（核心修复）  
'cat_smooth': 21, # 高基数分类特征平滑（防过拟合）
```

1

构建五层全连接隐藏层 + 一层输出层的MLP，将LGBM的预测值作为新的特征与其他特征共同输入神经网络模型训练

MAE爆炸

2

修改训练方式：去除独热编码后分类特征，将LGBM的预测残差作为因变量预测

提升极小

===== 测试集真实MAE详细结果（反logp1后） =====

测试集单独LGBM的真实MAE: 152655.147187

测试集LGBM+NN融合的真实MAE: 152671.787093

测试集MAE绝对下降值: -16.639906

测试集MAE提升幅度: -0.0109%



	Price					Rent			
	In-sample MAE	Out-of-sample MAE	6-fold CV MAE	Kaggle		In-sample MAE	Out-of-sample MAE	6-fold CV MAE	Kaggle
前最优(劣数据)	383616.6	308819	309638.6	38	前最优(劣数据)	88588.14	89181.28	88873.74	38
OLS(优数据)	227662	234918	235148	70	OLS(优数据)	60198	62190	62028	70
LGBM	145385	155765	157892	74.5	LGBM	46815	51540	50807	74.5
LGBM (调参)	84592.89	131560.1	132483.4	75.5	LGBM (调参)	32241.94	46932.12	46727.16	75.5
集成学习	-	135789	-	75.3	集成学习	-	47550.68	-	75.3
集成学习(调参)	-	132383.6592	-	74.9	最优模型(调参)	-	47005.9678	-	74.9