

人工智能金融期末汇报

汇报人：熊俊沣

学号：2023200193



模型和流程

用到的模型

RandomForest

原理：装袋采样 + 多棵决策树平均，显著降低方差-
调参：n_estimators 控规模；max_features 控分裂特征数；
bootstrap/max_samples 控样本抽样比例

CatBoost

原理：Ordered Boosting，基于有序统计减少目标泄露；对类别特征天然友好
调参：iterations 控轮次；depth 控深度；
l2_leaf_reg 控正则强度

LightGBM

原理：梯度提升，叶子优先 (leaf-wise) 增长，适合高维与稀疏
调参：num_leaves 控模型容量；learning_rate 控步长；
min_child_samples 控叶子最小样本数

XGBoost

原理：梯度提升树；tree_method='hist' 直方图分裂，高效稳健
调参：max_depth、min_child_weight 控复杂度；
subsample/colsample_bytree 控随机性；
lambda/alpha 控正则

训练与度量

目标变换：训练用 $\log_1 p$ ，预测反变换 $\exp m_1$ ，提升稳健性；
验证与交叉验证：记录 MAE/RMSE 与 3 折 CV RMSE，用于对比与融合加权。

Xgboost优化

Optuna超参数优化

目标：在验证集上优化少量关键超参，结合早停提升泛化

维度：max_depth、min_child_weight、subsample、colsample_bytree、lambda、alpha、gamma、learning_rate

步骤：子集验证 → 早停选择 → 将最优小范围参数回写到全量训练

Bagging 多种子

做法：设定多个随机种子训练若干子模型，对测试预测做均值

作用：在树模型中显著降低方差，提升稳定性；与小规模调参（降偏差）协同

融合与成果

Stacking（二层融合）：用多个基础模型的验证预测作为特征，再训练一个简单的线性模型（如Ridge）进行二次学习，自动调整各模型的偏差与权重。优势是能纠正系统性误差、提升稳健性与泛化，适合模型互补的场景。

加权融合（Blended）：依据各模型在验证集上的误差（如MAE）倒数分配权重，对它们的预测做线性加权求和。优势是实现简单、计算高效、可解释性强，能快速稳定地整合多模型信息作为可靠基线。

房价

Metrics	In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Sc...
RandomForest	421877.077171182...	891449.5300343917	808624.3638447054	74.8
XGBoost	570637.7924907828	1009297.13273699...	769451.8627309742	74.1
LightGBM	494351.8480770491	1015173.36578769...	670826.1194866408	74.5
CatBoost	821518.4207551314	1094812.11220851...	852226.9436430688	72.6
XGBoost_Bagg...	563326.1701247523	1037206.47979881...	665105.3683224387	74.1

租金

Metrics	In sample rmse	out of sample rmse	Cross-validation rmse	Kaggle Sc...
RandomForest	135191.192102278...	273568.901411001...	238849.99808210475	74.8
XGBoost	181032.672449144...	339078.135914594...	234175.05973069102	74.1
LightGBM	163393.8758654743	315924.2217138598	216243.97051794486	74.5
CatBoost	263847.460714961...	340488.99730762	270045.7773497847	72.6
XGBoost_Bagg...	178367.228307554...	351275.416097722...	215974.56048301948	74.1