



中國人民大學
RENMIN UNIVERSITY OF CHINA


Final Exam Presentation

唐子云 2023200198


Kaggle: Z0ne_zzz

2025年12月


PHASE 1: NLP Unstructured Data Processing




PHASE 2: Feature Engineering Construction



PHASE 3: Multi-stage Denoising & Filtering











PHASE 4: Model Training & Fusion



Legend: [Blue] NLP Phase, [Green] Feature Engineering, [Orange] Denoising, [Purple] Modeling & Fusion.
Rectangles=Process. Parallelograms=Data. Rounded Rectangles=Start/End.

模型表现

Price	样本内 RMSE	样本外 RMSE	交叉验证 RMSE	Kaggle 分数
期中线性模型	499723.20	540262.52	1114245.04	60.0
XGBoost	366613.55	568359.84	365918.47	77.5
多模型Stacking融合	341825.86	561450.84	-	77.5
最佳模型	341825.86	561450.84	-	77.5
Rent	样本内 RMSE	样本外 RMSE	交叉验证 RMSE	Kaggle 分数
期中线性模型	99353.20	114685.21	281518.00	60.0
XGBoost	118195.71	149514.10	118148.19	77.5
多模型Stacking融合	112391.35	147554.84	-	77.5
最佳模型	112391.35	147554.84	-	77.5



核心创新点

1. **跨模态语义特征挖掘**: 通过引入 **Roberta情感分类** 提取“客户反馈”中的情感得分, 捕捉客户反馈中包含的情感信息。
2. **三层地理空间建模架构**: 本项目构建了“宏观 (基于城市/区县的贝叶斯平滑TE) + 中观 (基于经纬度的KMeans聚类) + 微观 (基于经纬度的KNN邻域均值)”的三层地理特征体系。既捕获了板块的行政属性, 还捕捉了物理空间的连续性。
3. **初步模型残差降噪**: 在正式训练模型前用简单LightGBM模型进行初步“试跑”, 将模型无法学习到的异常离群点予以剔除, 项目里剔除了RMSE最大的前0.5%。
4. **多种子+KFold+双层模型架构stacking融合**:
 - 第一层: CatBoost、LightGBM、XGBoost 并行训练。
 - **CatBoost**: 擅长处理类别特征。
 - **LightGBM**: 训练高效且精度高。
 - **XGBoost**: 补充模型多样性。
 - 第二层: Ridge 回归模型进行stacking融合。
 - **Ridge**: 用于自动计算各模型权重, 且其正则化项能有效防止过拟合。
 - 多种子+KFold策略:
 - 对 CatBoost、LightGBM、XGBoost 使用交叉验证+多种子进行多轮预测, 并对各模型的每次预测结果进行简单平均。
 - 将平均后的结果作为 Ridge 模型的输入特征, 训练最终模型。