

模型性能对比表

Metrics	In-sample RMSE	Out-of-sample RMSE	Cross-validation RMSE	R ²	Kaggle Score
随机森林	269911.51	711373.47	749279.58	0.92	51.8
XGBoost	500274.52	728465.39	728349.00	0.92	-
LightGBM	707571.81	779118.36	813210.58	0.91	-
梯度提升	1204957.49	1241733.48	1240376.48	0.76	-
Lasso回归	1979550.38	1976910.74	1980122.99	0.40	30.9
Ridge回归	1979529.04	1976915.21	1980083.75	0.40	30.9

创新点（与期中模型相比）

- 使用TF-IDF文本分析技术分析文本数据

TF-IDF = Term Frequency - Inverse Document Frequency

中文：词频-逆文档频率

评估一个词对于一个文档集或语料库中的一份文档的重要程度

TF = 某个词在文档中出现的次数 / 文档总词数

IDF = $\log(\text{文档总数} / \text{包含该词的文档数} + 1)$

TF-IDF = TF × IDF

重要的词应该在当前文档中频繁出现，但在所有文档中很少出现

```
from sklearn.feature_extraction.text import TfidfVectorizer
    # 创建TF-IDF向量器
    self.tfidf_vectorizer = TfidfVectorizer(
        max_features=100, # 只取最重要的100个词
        min_df=5, # 词至少在5个文档中出现
        max_df=0.9, # 词至多在90%的文档中出现
        stop_words=stop_words # 去除"的、了、在"等停用词
    )
    # 训练（只在训练集上！）
    X_train_tfidf = self.tfidf_vectorizer.fit_transform(train_texts)
    # 获取特征词
    feature_names = self.tfidf_vectorizer.get_feature_names_out()
```

Top 10 最重要的常规特征 (随机森林):

建筑面积_数值: 0.324887
城市: 0.271620
环线: 0.041123
区县_小区: 0.038667
区域: 0.036222
硬件设施得分: 0.031881
环线_小区: 0.028788
物业管理得分: 0.022818
板块: 0.021470
板块_小区: 0.018942

Top 10 最重要的TF-IDF特征 (随机森林):

TFIDF_普通交易: 0.023530
TFIDF_普通交易地铁: 0.016944
TFIDF_产优质面积佳户型好龄新: 0.003738
TFIDF_产良好面积佳户型好设施全: 0.003097
TFIDF_产良好面积佳户型好龄新: 0.002830
TFIDF_信息适位置好配全: 0.002039
TFIDF_信息一般位置好: 0.001578
TFIDF_良好社区低密度社区高绿化率出行方便: 0.001341
TFIDF_良好社区硬件设施良好高绿化率: 0.001219
TFIDF_信息一般位置好配全: 0.001184

 TF-IDF特征总重要性: 8.0%

TF-IDF特征数量: 100 个

平均每个TF-IDF特征重要性: 0.000803