

模型性能对比表

Metrics	In-sample RMSE	Out-of-sample RMSE	Cross-validation RMSE	R ²	Kaggle Score
随机森林	269911.51	711373.47	749279.58	0.92	51.8
XGBoost	500274.52	728465.39	728349.00	0.92	51.6
LightGBM	707571.81	779118.36	813210.58	0.91	48.6
梯度提升	1204957.49	1241733.48	1240376.48	0.76	43.4
Lasso回归	1979550.38	1976910.74	1980122.99	0.40	30.9
Ridge回归	1979529.04	1976915.21	1980083.75	0.40	30.9

创新点（与期中模型相比）

- 使用TF-IDF文本分析技术分析文本数据

TF-IDF = Term Frequency - Inverse Document Frequency

中文：词频-逆文档频率

评估一个词对于一个文档集或语料库中的一份文档的重要程度

TF = 某个词在文档中出现的次数 / 文档总词数

IDF = $\log(\text{文档总数} / \text{包含该词的文档数} + 1)$

TF-IDF = TF × IDF

重要的词应该在当前文档中频繁出现，但在所有文档中很少出现

```
from sklearn.feature_extraction.text import TfidfVectorizer
    # 创建TF-IDF向量器
    self.tfidf_vectorizer = TfidfVectorizer(
        max_features=100, # 只取最重要的100个词
        min_df=5, # 词至少在5个文档中出现
        max_df=0.9, # 词至多在90%的文档中出现
        stop_words=stop_words # 去除"的、了、在"等停用词
    )
    # 训练（只在训练集上！）
    X_train_tfidf = self.tfidf_vectorizer.fit_transform(train_texts)
    # 获取特征词
    feature_names = self.tfidf_vectorizer.get_feature_names_out()
```

Top 10 最重要的常规特征 (随机森林):

建筑面积_数值: 0.324887
城市: 0.271620
环线: 0.041123
区县_小区: 0.038667
区域: 0.036222
硬件设施得分: 0.031881
环线_小区: 0.028788
物业管理得分: 0.022818
板块: 0.021470
板块_小区: 0.018942

Top 10 最重要的TF-IDF特征 (随机森林):

TFIDF_普通交易: 0.023530
TFIDF_普通交易地铁: 0.016944
TFIDF_产优质面积佳户型好龄新: 0.003738
TFIDF_产良好面积佳户型好设施全: 0.003097
TFIDF_产良好面积佳户型好龄新: 0.002830
TFIDF_信息适位置好配全: 0.002039
TFIDF_信息一般位置好: 0.001578
TFIDF_良好社区低密度社区高绿化率出行方便: 0.001341
TFIDF_良好社区硬件设施良好高绿化率: 0.001219
TFIDF_信息一般位置好配全: 0.001184

 TF-IDF特征总重要性: 8.0%

TF-IDF特征数量: 100 个

平均每个TF-IDF特征重要性: 0.000803