

Final Presentation

Sno:2023200231 kaggleID-RhHannahZhao 赵若涵

Raw CSV



AdvancedDataProcessor

- 基础清洗: common (area/停车费/ring line...) + specific (inner area ratio/floor & floor ratio...)
- 缺失值处理: 分级填充 (按 '板块', '区域', '城市') + 空间插值 (KNN by 经纬度)
- 文本处理: TF-IDF + Sentiment
- Cross-feature construction : house age/total rooms/Ring_Area_Inter/geo clusters by 经纬度...



Model Zoo

- LGBM: 处理非线性 + 自动特征选择
- XGBoost
- Neural Network (PyTorch): 高阶 interaction + text × numeric




Stacking / Model Selection



Price / Rent Separate Output

- 继承期中的EDA+feature+CV
- 封装pipeline



模型名称	rmse_log	MAE_Orig	Kaggle Score
Midterm Ridge		235,221	68.8
lgbm (Price)	0.12985	221,071	76.7
xgb (Price)	0.12263	206,321	77.6
nn (Price)	0.28294	509,657	68.9
stacking (Price)	0.12169	204,628	77.7

模型名称	rmse_log	MAE_Orig	Kaggle Score
Midterm Ridge		56,281	68.8
lgbm (Rent)	0.17040	68,296	76.7
xgb (Rent)	0.16617	65,876	77.6
nn (Rent)	0.29208	130,814	68.9
stacking (Rent)	0.16576	65,664	77.7

Final Presentation

Sno:2023200231 kaggleID-RhHannahZhao 赵若涵

Cleaning & Parsing

- 正则解析 如户型拆解 `room = re.search(r'(\d+)', str(layout_str))`;
- 语义解析 → 数值化 如楼层相对高度映射 `pos_map = {'低':1, '中':2, '高':3, '底':0, '顶':4}`, 环线映射 1-6 级
- 数值清理 处理百分比、范围及单位剥离

Smart Imputation



- `hierarchical_fill` 层级填补。板块->区域->全局 `median`, 填充停车费等
- `spatial_knn_fill` 利用经纬度, KNN 寻找空间 5 近邻, 填补建筑年代、容积率等

Feature Engineering

- `Geo_cluster` 利用 K-Means 对经纬度进行聚类 (`n_clusters=30`), 捕捉社区效应
- 衍生交互特征 `House_Age`、`Avg_Room_Area`、`Ring_Area_Inter...`

文本分析 (NLP & Sentiment Analysis)

- `extract_sentiment_features` 基于地产垂直领域的正负向词库 (如 “通透、全、美” vs “吵、旧、差”), 对客户反馈和卖点描述进行打分。
- `nlp_features` 使用 TF-IDF 提取字符级特征, 并通过 SVD 奇异值分解将高维稀疏矩阵降维至 5 个稠密特征, 捕捉潜在语义。
- 适配树模型+防止过拟合+降维 与数值类别特征兼容



Final Presentation

Sno:2023200231 kaggleID-RhHannahZhao 赵若涵

Model Zoo - Base Learners:

- **LightGBM**: 基于直方图的梯度提升决策树, 对异常值不敏感, 训练速度快。
- **XGBoost**: 经典的梯度提升框架, 在损失函数中加入了二阶泰勒展开, 收敛更稳定。
- **Advanced MLP (NN)**: 深度神经网络, 负责捕捉特征之间的非线性高阶交互关系。

Tree model

- 长迭代次数 ($n_estimators=8000$) 配合 `early_stopping`, 自动寻找最佳收敛点, 防止过拟合
- 小学习率 (逐步调小至0.01) 和子采样策略 (`colsample_bytree` 约 0.6-0.7) 提升泛化能力

Neural network

- **QuantileTransformer** 预处理, 将输入特征强制转换为标准正态分布。解决 NN 在表格数据上训练困难。
- **Linear -> BatchNorm -> LeakyReLU -> Dropout** 的标准块。
BatchNorm 加速收敛, **Dropout** 配合 **Weight Decay** 防止过拟合。
- 权值初始化: 使用 **Kaiming Normal** 初始化, 专门适配 **LeakyReLU** 激活函数。
- 采用 **AdamW** 优化器和 **ReduceLROnPlateau** 学习率衰减策略。
- **HuberLoss**: 相比 **MSE**, 对异常值更不敏感。



Stacking

Base Models:

- **5-Fold CV**, 模型A对训练集生成一份完整的预测结果Pa, 由 5 段验证集拼接而成。
- 同理生成Pb, 神经网络生成Pnn。

构造新特征空间:

- 将[Pa, Pb, Pnn]组合成一个新的特征矩阵 $X_{\{meta\}}$, [训练集样本数, 3]。

Meta-Model:

- **Ridge Regression** 岭回归 作为元模型。
- 由于不同模型对同一房价的预测高度相关, 共线性强, **Ridge** 通过 **L2** 正则化可以有效分配权重, 防止元模型过拟合, 提高融合的鲁棒性。

树模型擅长处理类别和离散特征, 神经网络擅长高阶连续特征交互, **Stacking** 融合了不同算法的归纳偏置。

多样性: 表格数据中树模型具有天然优势, 但 **NN** 提供了差异化的残差, 在 **Stacking** 阶段能修正树模型的残差。

最终: 统一执行 $\log_{1p}$ 的反向变换 `expm1`, 对预测值进行非负截断 `clip(lower=0)`, 按 ID 排序生成提交文件。