

# Midterm Presentation

Sno:2023200231    kaggleID-RhHannahZhao

## innovation1: EDA: Dirty Data -> Clean Features -> Refined Models

- data cleansing:text(e.g. comment---->情感分析? too complicated;risk of data leaking)
- 数据填充:    numeric: median? knn?    category: 众数&one hot code
- Handling Skewness: 对目标变量采用 `np.log1p` 转换, 使数据更符合线性模型的正态性假设

## innovation2: Feature Engineering


- `Regex`+`Pandas.apply`+`Sklearn Pipeline`
- Structured Parsing: `parse\_layout\_price` ("3室2厅1厨2卫") vs `parse\_layout\_rent` ("2室2厅1卫");`parse\_floor\_...` ("中楼层 (共23层)" / "4/6层")
- Text-Numeric Cleaning: `parse\_area\_price` ("282.02m²") ;`clean\_numeric\_text` ("45%");`clean\_parking` ("免费")
- Derived Features: `HouseAge`=`TransactionYear`-`BuildingYear`
- use pipeline: simple imputer & standard scaler -- train on train set and process test set

## innovation3: Cross-Task Feature Fusion

- `Pandas.groupby`+`merge`
- Price引入平均租金: `train\_rent.csv`--`AvgRent\_Community`,Rent引入平均售价: `train\_price.csv`--`AvgPrice\_Community`
- 为线性模型提供了强大的、基于租售比的金融信号

## innovation4: Robust Validation

- `np.log1p`+`make\_scorer`+`GridSearchCV`
- 自定义评估函数: `mae\_on\_original\_scale` 函数,用 `np.expm1` 将结果逆转换回原始价格后再计算 MAE
- Optimizing Real Metric: `mae\_scorer` 传递给 `GridSearchCV(..., scoring=mae\_scorer)`,确保超参数调优是直接优化最终的业务指标--原始价格MAE



| 模型名称               | In sample | out of sample | CV      | Kaggle Score |
|--------------------|-----------|---------------|---------|--------------|
| OLS (Price)        | 220,587   | 248,458       | 236,420 | 68.43        |
| Lasso (Price)      | 411,051   | 413,690       | 412,289 | 62.26        |
| Ridge (Price)      | 222,899   | 224,268       | 235,221 | 68.80        |
| ElasticNet (Price) | 338,494   | 340,599       | 340,950 | 64.78        |
| LGBM (Price)       | 393,081   | 390,973       | 149,536 | 74.05        |

| 模型名称              | In sample | out of sample | CV     | Kaggle Score |
|-------------------|-----------|---------------|--------|--------------|
| OLS (Rent)        | 52,926    | 56,917        | 56,315 | 68.43        |
| Lasso (Rent)      | 86,554    | 87,045        | 86,794 | 62.26        |
| Ridge (Rent)      | 53,347    | 54,043        | 56,281 | 68.80        |
| ElasticNet (Rent) | 71,509    | 71,761        | 71,955 | 64.78        |
| LGBM (Rent)       | 118,670   | 119,765       | 48,372 | 74.05        |

# Midterm Presentation

学号:2023200193    kaggleID: xjfaaa-0193    姓名: 熊俊沣

## 1.智能数据预处理与安全类型转换:

- 核心逻辑**: 通过正则表达式匹配和基于列名的语义分析, 自动判断该进行数值转换还是分类编码。对于疑似数值型的列(如包含“面积”、“数量”等关键词), 使用正则表达式
- 安全转换**: safe\_numeric\_conversion函数是此环节的基石。它能智能处理带单位的字符串, 例如将“123.7m²”安全地转换为数值123.7, 并对转换成功率进行监控, 为后续处理提供依据。
- 容错机制**: 整个流程被包裹在异常捕获 (try-catch) 中, 单列处理的失败不会导致整个流程中断, 极大增强了系统的鲁棒性

## 2.多策略混合编码应对高基数分类变量

**低基数特征频率与目标编码**: 对于唯一值较少的分类变量(如“装修情况”), 我们主要采用**频率编码**, 用每个类别在数据集中出现的次数作为其数值。有时会辅以**目标编码**(在有目标变量且基数非常低时), 用该类别对应目标变量的均值(经过平滑处理)来编码, 更能体现其与房价的关系

**高基数特征哈希与频率编码**: 对于唯一值很多的特征(如“周边配套”描述文本), 独热编码会产生大量特征。我们采用**哈希编码**, 将类别值映射到固定维度的空间(如1000维), 有效控制维度。同时也会使用频率编码作为补充。

## 3.深度时空特征与地理网格创新

**时间特征深度解析**: 从“交易时间”等日期字段中, 不仅提取年份、月份、季度等基础信息, 还创新性地生成**周期性编码**(通过正弦余弦转换月份等周期数据)和**市场季节性标志**(如标识3-5月、9-10月为租赁旺季), 帮助模型捕捉市场的周期规律。

**多粒度地理网格**: 利用经纬度信息, 在不同精度级别(如0.001度, 0.01度)上创建**地理网格特征**, 将连续的地理坐标转换为离散的网格ID, 从而表征微观地理位置差异。

**多中心距离计算**: 计算每个房源到多个城市重要节点(如市中心、商业中心、交通枢纽)的欧氏距离, 生成一系列**区位特征**, 量化了房源的相对区位价值

| 模型名称       | In sample | out of sample | CV     | Kaggle Score |
|------------|-----------|---------------|--------|--------------|
| OLS        | 0.4369    | 0.4333        | 0.4303 | 45.90        |
| Lasso      | 0.5490    | 0.5452        | 0.5491 | 42.69        |
| Ridge      | 0.4369    | 0.4332        | 0.4374 | 45.89        |
| ElasticNet | 0.4911    | 0.4872        | 0.4912 | 33.44        |

| 模型名称       | In sample | out of sample | CV     | Kaggle Score |
|------------|-----------|---------------|--------|--------------|
| OLS        | 0.4244    | 0.4256        | 0.4248 | 45.90        |
| Lasso      | 0.5199    | 0.5164        | 0.5200 | 42.69        |
| Ridge      | 0.4244    | 0.4256        | 0.4248 | 45.89        |
| ElasticNet | 0.4713    | 0.4694        | 0.4714 | 33.44        |

# 期中课堂展示

2023200190 徐国祥

## 创新1：特征利用

利用‘客户反馈’数据，借助人工智能（豆包）分析获取分主题关键词、情感词，按‘，’切割分句对主题词出现频度进行打分，乘以情感系数，并除以关键词出现的总次数以排除句子长短带来的影响

## 创新2：数据处理

1 对‘楼层位置’分箱处理：所处楼层在总楼层数的百分比、以1/3为界，分为低、中、高楼层

2 对‘朝向’简化处理：将杂乱朝向分类提取为主要朝向  
依据‘城市’分别处理：‘城市’编码不同，数据缺失特征也不同，按照‘城市’分类对缺失值进行填补

## 创新3：模型构建

依据‘城市’缺失特征构建二值变量，利用get\_high\_missing\_cols函数了解‘城市’系统性缺失，并与原特征交乘，捕捉‘缺失’对房价/租金的影响

```
topic_keywords = {
    "设施硬件": ["光照", "通风", "网速", "阳台", "装修", "照明灯", "结构", "厨房", "储物", "水",
    "空间布局": ["面积", "布局", "路况", "地铁", "楼间距", "空间", "风景", "道路", "房型", "出行",
    "环境体验": ["体验", "素质", "潮气", "气味", "交通", "绿植", "隔音", "地段", "绿化", "通勤",
    "服务配套": ["服务", "成熟度", "安保", "保安", "维修", "安防", "管理", "监控", "智能", "社区",
}

positive_words = {"快", "通透", "稳定", "时尚", "预留", "标准", "顺畅", "完善", "新颖", "舒适",
negative_words = {"老旧", "松动", "进风", "漏水", "渗水", "裂", "停用", "坏", "破损", "异响",
```

```
df_chengshi_8 = max_min_filler(df_chengshi_8)
print(get_high_missing_cols(df_chengshi_8))
```

```
[15]
... 共发现 6 列缺失值占比超过 50.0%:
- 列 '装修': 缺失值 5973 个, 占比 82.11%
- 列 '车位': 缺失值 6115 个, 占比 84.07%
- 列 '采暖': 缺失值 6411 个, 占比 88.14%
- 列 '环线位置': 缺失值 7274 个, 占比 100.00%
- 列 '供热费下限': 缺失值 5834 个, 占比 80.20%
- 列 '供热费上限': 缺失值 5834 个, 占比 80.20%
['装修', '车位', '采暖', '环线位置', '供热费下限', '供热费上限']
```

```
1 #依据城市缺失型添加
2 df_train_price_fill = df_train_price_fill.drop(['套内面积', '板块'],axis=1)
3 df_train_price_fill['是否无环线'] = (df_train_price_fill['城市'].isin([1,2,3,5,6,7,8,9,10,11])).astype(int)
4 df_train_price_fill['是否无暖气'] = (~df_train_price_fill['城市'].isin([0,1,2,4,6,11])).astype(int)
5 df_train_price_fill['是否无房屋年限'] = (df_train_price_fill['城市'].isin([3,5,6,7,8,9,11])).astype(int)
6 df_train_price_fill['是否无绿化率_停车位_平均燃气费'] = (df_train_price_fill['城市'].isin([3,9])).astype(int)
7 df_train_price_fill['是否无停车费用'] = (df_train_price_fill['城市'].isin([3,6,9])).astype(int)
8 df_train_price_fill['是否无交易权属'] = (df_train_price_fill['城市'].isin([7,8])).astype(int)
9 df_train_price_fill['是否无房屋楼栋和社区位置'] = (df_train_price_fill['城市'].isin([9])).astype(int)
10 df_train_price_fill['是否无两次交易间隔'] = (df_train_price_fill['城市'].isin([5,6,8,9,11])).astype(int)
11 df_train_price_fill['是否无平均年代'] = (df_train_price_fill['城市'].isin([3,5,9])).astype(int)
12
```

| 模型名称           | In sample | out of sample | CV        | Kaggle Score |
|----------------|-----------|---------------|-----------|--------------|
| OLS (Price)    | 310241.27 | 308818.99     | 309638.60 | 37.97        |
| Lasso (Price)  | 383616.64 | 382054.93     | 380133.79 | -21.92       |
| Ridge (Price)  | 383580.09 | 381988.32     | 380127.93 | -22.18       |
| Neural Network | 0.1794    | 0.1780        | 0.1703    | 42.48        |

| 模型名称           | In sample | out of sample | CV          | Kaggle Score |
|----------------|-----------|---------------|-------------|--------------|
| OLS (Rent)     | 75676.43  | 75518.1396    | 131858.8085 | 37.97        |
| Lasso (Rent)   | 88588.14  | 89181.28      | 88873.74    | -21.92       |
| Ridge (Rent)   | 88585.26  | 89180.91      | 88871.27    | -22.18       |
| Neural Network | 0.1882    | 0.1871        | 0.1852      | 42.48        |

# 期中课堂展示

学号：2023200203

KaggleID:usagi-yang

姓名：杨姝钰

## 数据处理与特征工程

Y: Y\_log,Y\_test\_log,预测Y\_new

X: X, X\_test,使用X\_new预测

对数处理:  $\log_{1p}(x) = \log(x + 1)$

环线使用经纬度聚类方法填充，无法聚类（无环线）为0。

特征工程中进行3倍IQR异常值处理

复杂指标打分填充。使用相关性、VIF、Lasso筛选

| 类别 | 相关性分析、VIF、Lasso特征筛选后的指标                                         |
|----|-----------------------------------------------------------------|
| 房价 | 建筑面积_数值, 供暖评分, 房屋年限评分, 环线_数值, 装修评分, 梯户比评分, 燃气费评分, 楼栋总数评分, 城市    |
| 租金 | 面积_数值、停车费用_量化、采暖_量化、环线_数值、停车位_量化、配套设施_量化、付款方式_量化、用水_量化、租期_量化、城市 |

## 模型结果


|   | 模型          | 数据集 | MAE    | RMAE   | R <sup>2</sup> | 调整后R <sup>2</sup> |   | 模型          | 数据集 | MAE    | RMAE   | R <sup>2</sup> | 调整后R <sup>2</sup> |
|---|-------------|-----|--------|--------|----------------|-------------------|---|-------------|-----|--------|--------|----------------|-------------------|
| 0 | 线性回归        | 训练集 | 0.4686 | 0.0330 | 0.3774         | 0.3773            | 0 | 线性回归        | 训练集 | 0.4430 | 0.0343 | 0.3740         | 0.3739            |
| 1 | 线性回归        | 测试集 | 0.4881 | 0.0342 | 0.4403         | 0.4400            | 1 | 线性回归        | 测试集 | 0.4505 | 0.0348 | 0.4487         | 0.4484            |
| 2 | Lasso       | 训练集 | 0.4686 | 0.0330 | 0.3774         | 0.3773            | 2 | Lasso       | 训练集 | 0.4430 | 0.0343 | 0.3740         | 0.3739            |
| 3 | Lasso       | 测试集 | 0.4882 | 0.0342 | 0.4403         | 0.4400            | 3 | Lasso       | 测试集 | 0.4505 | 0.0348 | 0.4487         | 0.4484            |
| 4 | Ridge       | 训练集 | 0.4686 | 0.0330 | 0.3774         | 0.3773            | 4 | Ridge       | 训练集 | 0.4430 | 0.0343 | 0.3740         | 0.3739            |
| 5 | Ridge       | 测试集 | 0.4881 | 0.0342 | 0.4403         | 0.4400            | 5 | Ridge       | 测试集 | 0.4505 | 0.0348 | 0.4487         | 0.4484            |
| 6 | Elastic Net | 训练集 | 0.4686 | 0.0330 | 0.3774         | 0.3773            | 6 | Elastic Net | 训练集 | 0.4430 | 0.0343 | 0.3740         | 0.3739            |
| 7 | Elastic Net | 测试集 | 0.4882 | 0.0342 | 0.4403         | 0.4400            | 7 | Elastic Net | 测试集 | 0.4505 | 0.0348 | 0.4487         | 0.4484            |

| Metrics     | In sample | out of sample | Cross-validation | Kaggle Score |
|-------------|-----------|---------------|------------------|--------------|
| OLS         | 0.4686    | 0.4881        | 0.4686           | 30.96        |
| Lasso       | 0.4686    | 0.4882        | 0.4687           | 30.96        |
| Ridge       | 0.4686    | 0.4881        | 0.4686           | 30.96        |
| Elastic Net | 0.4686    | 0.4882        | 0.4686           | 30.96        |

| Metrics     | In sample | out of sample | Cross-validation | Kaggle Score |
|-------------|-----------|---------------|------------------|--------------|
| OLS         | 0.4430    | 0.4505        | 0.4431           | 30.96        |
| Lasso       | 0.4430    | 0.4505        | 0.4431           | 30.96        |
| Ridge       | 0.4430    | 0.4505        | 0.4431           | 30.96        |
| Elastic Net | 0.4430    | 0.4505        | 0.4431           | 30.96        |

## 创新点（着重数据处理和特征工程）

### 聚类



打分 以处理时最为棘手的“房屋朝向”列为例

```
# 计算基础分（有效朝向的平均分）
base_score = sum(orientation_base_score[o] for o in valid_orientation) / len(valid_orientation)

# 计算数量加分（种类数量）
num_types = len(valid_orientation)
if num_types == 1:
    add_score = 0
elif num_types == 2:
    add_score = 1
else: # 3种及以上
    add_score = 2

# 总分（保留2位小数）
total_score = round(base_score + add_score, 2)
return total_score
```