

# 第九组汇报

组员：张祖豪、杨嘉皓、杨舒惠、李怡伽

## Price Model

| Metrics    | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|------------|-----------|---------------|------------------|--------------|
| OLS        | 368916.5  | 374564.48     | 370058.95        | 67.78        |
| Lasso      | 381476.18 | 387115.96     | 381442.54        | 66.93        |
| Ridge      | 369204.36 | 374989.79     | 369162.16        | 67.16        |
| ElasticNet | 369774.26 | 375548.83     | 369135.69        | 68.61        |

## Rent Model

| Metrics    | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|------------|-----------|---------------|------------------|--------------|
| OLS        | 89436.09  | 90939.98      | 89648.54         | 67.78        |
| Lasso      | 91935.42  | 93635.33      | 91935.42         | 66.93        |
| Ridge      | 89440.21  | 90955.11      | 89440.21         | 67.16        |
| ElasticNet | 89807.83  | 91472.57      | 89807.83         | 68.61        |

## 关键点

1. 抓住主要特征：决定房价/租金的最主要因素是地理位置和面积。城市-区县-板块都重要，都保留。城市/区县独热编码；板块相对编码，计算板块均值与区县均值的差异，捕捉同一区县内不同板块的差异，加入平滑系数处理小样本板块。房价偏度较大通过取对数处理。

$$\text{相对编码值} = \frac{\text{板块均值} \times \text{板块样本数} + \text{区域均值} \times \alpha}{\text{板块样本数} + \alpha} - \text{区域均值}$$

2. 特征选择：通过计算特征变量与目标变量相关性删去低相关性变量，计算特征之间的相关性删去高相关性特征，再通过vif检验进一步删特征。除去冗余变量，且有效避免多重共线性。（ols模型结果较好）

3. 长文本处理：先观察训练集手动提取关键词，再通过豆包生成更多同类型关键词，统计文本中关键词出现的频率进行计分。

## Price Model

| Metrics | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|---------|-----------|---------------|------------------|--------------|
| OLS     | 320891.05 | 346894.38     | 334636.83        | 65.96        |
| Lasso   | 710060.04 | 784314.35     | 852408.57        | 65.98        |
| Ridge   | 321564.20 | 513767.09     | 1313767.06       | 65.97        |

## Rent Model

| Metrics | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|---------|-----------|---------------|------------------|--------------|
| OLS     | 112643.27 | 112283.35     | 112811.85        | 65.96        |
| Lasso   | 112789.75 | 112346.83     | 112942.90        | 65.98        |
| Ridge   | 112643.50 | 112283.89     | 112812.16        | 65.97        |

## 创新点

1. 对于Price和Rent使用两种处理方法：一种是保留所有因变量进行回归，对于租金模型只抓取关键变量例如区域、面积等进行回归。
2. 对于Rent模型的特征选择：通过计算特征变量与目标变量相关性删去低相关性变量，计算特征之间的相关性删去高相关性特征，再通过vif检验进一步删特征（虽然代码里我把VIF部分又删除了）。除去冗余变量，且有效避免多重共线性。对于Price模型的特征引入面积的平方、房龄等直观感受较重要的变量并做平方项和交叉项
3. 文本处理：先观察训练集手动提取关键词，对于Price模型中文字文本进行积极消极处理并简略计算得分作为综合反馈变量进行回归

| Model      | 训练集MAE    | 测试集MAE    | 交叉验证MAE   | KAGGLE |
|------------|-----------|-----------|-----------|--------|
| OLS        | 159119.51 | 244671.97 | 159213.50 | 4.06   |
| Ridge      | 159119.21 | 244672.28 | 159224.72 | 4.06   |
| Lasso      | 159119.12 | 244671.83 | 159224.71 | 4.06   |
| ElasticNet | 169565.78 | 257518.99 | 169618.04 | 4.33   |



```
# One-hot编码 (低基数特征) 将每个类别变成单独0/1列
# 如果存在低基数特征: 类别少, 拆成多列也不会太多, 而且能保留每个类别的独特信息
if low_cardinality_cols:
    # 使用pd.get_dummies进行one-hot编码, drop_first=True避免多重共线性
    X_price_encoded = pd.get_dummies(X_price_encoded, columns=low_cardinality_cols, drop_first=True)

# 频率编码 (高基数特征):: 将类别替换成出现频率
# 创建字典存储频率编码映射
freq_encoding_dict = {}
# 遍历所有高基数列
for col in high_cardinality_cols:
    # 计算每个类别的频率 (归一化)
    freq_encoding = X_price_encoded[col].value_counts(normalize=True).to_dict()
    # 保存频率编码字典, 供测试集使用
    freq_encoding_dict[col] = freq_encoding
    # 使用频率编码替换原列, 创建新的频率特征列
    X_price_encoded[f'{col}_freq'] = X_price_encoded[col].map(freq_encoding)
    # 删除原始类别列
    X_price_encoded = X_price_encoded.drop(columns=[col])
```

- 采用One-hot编码方式和频率编码方式分别处理存在不同类别基数的类别特征
- 通过提取字符串内数据尽量保留有效特征
- 尝试通过布尔掩码达到有效筛选异常数据的目的
- 对数转换采用用log1p而不是log避免可能的X=0情况





## Price Model

| Metrics    | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|------------|-----------|---------------|------------------|--------------|
| OLS        | 508708.42 | 507006.78     | 512355.94        | 61.47        |
| Ridge      | 509073.16 | 507114.75     | 512936.92        | 61.45        |
| Lasso      | 532805.38 | 527799.62     | 534865.13        | 60.48        |
| ElasticNet | 522174.25 | 518961.39     | 525604.52        | 60.87        |

## Rent Model

| Metrics    | In Sample | Out of Sample | Cross-validation | Kaggle Score |
|------------|-----------|---------------|------------------|--------------|
| OLS        | 121502.33 | 123343.63     | 122168.61        | 61.47        |
| Ridge      | 121862.25 | 123613.01     | 122577.98        | 61.45        |
| Lasso      | 126782.19 | 128017.79     | 127216.36        | 60.48        |
| ElasticNet | 124518.82 | 125953.30     | 125131.07        | 60.87        |

## 创新点

1. **离群值处理**: IQR + log来去掉Price的离群值, 减少删除的样本数量
2. **类别变量处理**: 对于类别变量, 根据其类别多少分别采用Onehot encoder以及Target encoding进行处理, 对于诸如区域等变量取其在Price上的平均值作为特征, 避免产生大量稀疏矩阵
3. **特征选择**: 数值型变量生成交叉项和二次项, 01变量与数值变量生成交叉项; 采用Pearson相关系数, 并将筛选位置放在生成二次项和交叉项之后, 有效筛选出可用变量
4. **缺失值填补**: 对不同的缺失比例采取不同的填补策略, 均值填补缺失<10%, 分层均值填补10%-70%, 缺失比例>70%的删除

