

第十小组pre

章明阳 林琪岷 刘永泽



章明阳 2022201378

使用KNN重新获取地点信息, 添加特征 cluster label, 并使用独热编码


套内面积填充、房屋朝向、房屋户型计算得分、水电费等直接使用原始数据，部分使用独热编码

计算添加为新的交易间隔变量

得到 top-k 词云图，介绍类信息使用词云信息加分处理，客户反馈调用 Hugging Face 中模型计算得分 (0-1)

·线性模型在 Rent 数据集上测试结果较好, R方为0.65, Price 数据集只有0.03

·非线性模型表现优异, R方达到了0.85和0.89,Kaggle 得分达到了63.27



客户评价高频词前 20 词云



Housing Price Model Evaluation Metrics

Model	In sample	Out of sample	Cross-validation	Kaggle Score
OLS	890,947.53	868,977.13	892,021.94	25.91
LASSO	930,039.25	902,617.61	1,163,859.95	26.36
Ridge	890,947.38	868,976.94	892,003.55	29.62
ElasticNet	899,823.14	875,978.78	1,159,477.36	32.33

Rent Model Evaluation Metrics

Model	In sample	Out of sample	Cross-validation	Kaggle Score
OLS	161,722.54	159,723.11	161,786.04	25.91
LASSO	174,866.05	172,559.84	283,977.64	26.36
Ridge	161,722.56	159,723.10	161,788.21	29.62
ElasticNet	165,877.90	163,413.73	279,315.99	32.33



- 数据预处理
 - 任务差异化清洗，数据可视化
- 特征工程
 - 将 BERT 文本嵌入与结构化特征（分类、数值）深度融合（从参考关键词到BERT文本嵌入的选择）
- 模型参数微调
- 基于前两次作业的改进
 - redefining functions or variables, operate on a copy of the DataFrame, ensure reproducible results

模型	In sample	Out of sample	Cross-validation	Kaggle Score
OLS	100767. 7687	127051. 5078	127051. 5078	53. 91
LASSO	100058. 5344	125663. 5788	121144. 2602	53. 91
Ridge	100159. 7700	126145. 8116	121646. 3263	53. 91
ElasticNet	102605. 3111	124567. 4325	122795. 4957	53. 91

1. 数据处理

做了空值过滤：通过筛选非空值占比高的列（`non_null_counts_df1 > 90000` 等逻辑），保留核心有效特征，避免大量空值对后续分析的干扰。

做了去重操作（`drop_duplicates()`）：消除了冗余数据，保证每条记录的唯一性，保证数据纯净度。

对Price和面积做自然对数转换（`np.log`），有效处理这类右偏分布的数值特征。转换后特征分布更接近正态，能提升线性模型的拟合效果。

创建 “户均楼栋房屋数”（房屋总数 / 楼栋总数）这一衍生特征值

2. 建立模型

我尝试了OLS、Lasso、ElasticNet、Ridge四种线性模型，覆盖了 “无正则→L1 正则→L2 正则→L1 + L2 混合正则” 的全正则化场景，能对比不同正则化策略对房价预测任务的适配性，找到最适合数据的线性模型。且，保证其内部流程完全一样，保证性能对比完全公平，但是都有点过拟合了。

	In sample	out of sample	Cross-validation	Kaggle Score
OLS	323500	323400	446500	9.35
LASSO	323500	323400	446400	8.87
RIDGE	323500	323400	446500	12.89
ELASTIC	323500	323400	446500	14.63