

模型验证与评估报告

Group 11 的四位小组成员对 All_chain_merge.ipynb 项目代码进行了审阅与验证后，本报告旨在对该项目的模型构建逻辑、数据处理和特征工程细节等方面进行评估，并尝试提出一些有助于改进模型的操作建议。

整体而言，该项目展现了较为完整的端到端建模流程，代码结构清晰，且引入了梯度提升树（GBRT）与线性模型融合的架构，体现了 Group 1 对机器学习组合策略的熟练掌握。然而，该项目仍存在若干值得深思之处，下面列出了四位小组成员在群内讨论出的见解，大家的看法各有侧重，这里进行了整理：

黄之杰：

代码含注释能清楚了解数据处理和建模思路，特征工程环节处理细心，对于整个建模流程有以下问题或建议提供，亦有可能是本人未熟悉所用模型而造成的误解。

1. 环线等特征有空值直接用 nan 处理，可能是为了后面使用 gbrt 算法而提供的信息，而真实情况可能是该城市没有环线或单纯数值缺失，可以结合经纬度的数据来提取更多信息，这样在之后得到的叶节点信息亦更有价值。

2. 建筑年份直接用中值和停车费取第一个数值的处理方式是直觉上不错的，但可以尝试使多的潜在方式建造特征变量，不断测试得到更好的结果。停车费或可再分成更多的特征，地上、地下等，不过这部分缺失值过多亦无法保证增加变量的数值质量，透过方差分析等方法亦发现可能高估了这些变量的重要性。

3. 建模使用了 top10 等方法加入除叶节点外的信息，但无论是叶节点还是原始特征的重要性都是由 gbrt 提供，那么如何存在 gbrt 无法识别的信息，那这部分的信息就掉失了？或者可以使用其他模型来评估 top10,20 如此类推。

何宣晓：

1. 代码先将整个 train_price 进行了特征工程处理（如填充缺失值、创建哑变量、标准化等），然后再进行了模型的交叉验证，在交叉验证的每一折中，验证集都在特征工程阶段接触到了训练折的信息（如用所有数据计算建筑年份的中位数来填充缺失值，那么验证集在划分前就已经知道了训练集的统计分布），会有一定程度的数据泄露导致验证结果不可靠。

2. 特征工程对所给数据集的信息进行了充分的提取并加入了一些新特征，但还是可以利用领域知识创建更多的交互项和其他衍生特征，让模型更具经济学上的意义。

谢天伦：

我觉得关于城市编码，先把测试集和训练集合并起来提前知道了所有城市，虽然因为数据量很多不会对结果造成影响，但是仍然属于数据泄露。

应该仅对训练集的数据编码，再对测试集里的未知项按合理的方法重新编码。

我的建议是把所有特征工程放到 pipeline 里，确保 fit() 只在训练集进行，保

证不会发生数据泄露

另外，目前的代码只提取了 GBDT 模型本身的特征重要性，但我们的最终预测模型并不是单纯的 GBDT，而是“GBDT 生成特征 + RidgeCV 做最终预测”的两阶段模型结构。

GBDT 在这里更多扮演的是一个非线性特征转换器（feature encoder）的角色，它将原始特征映射到高维的叶节点空间，再由 RidgeCV 使用 one-hot 的叶节点特征进行最终拟合。因此，GBDT 的 feature importance 只能反映树模型在分裂时所依赖的特征，而不能代表我们最终模型真正使用的特征贡献。

我的建议是加上 RidgeCV 后再重新提取重要特征，明确每个叶节点特征对模型的贡献。

白博之：

就数据预处理层面而言，项目对非结构化文本信息的挖掘虽有亮点，但在部分数值填充策略上有些“一刀切”。比如对于“物业费”、“停车费”等具有强经济指示意义的特征，代码中直接将其缺失值填充为 0。此外，对于经纬度这一关键的空间地理信息，项目仅将其视为普通数值特征处理。房地产价格的核心在于“地段”，而原始的经纬度数值并不具备直接的线性解释力。项目未进行空间特征构造，忽略了通过地理位置挖掘临近区域价值、商圈距离等核心非线性因子的机会，这在特征挖掘的深度上显得较为浅薄。

建议可以先回归数据，细化数据填充策略。比如中位数填充算法以及 KNN 插值等填充方法，从而降低数据噪声对模型的影响；再者，建议挖掘地理位置的价值。比如利用 K-Means 对经纬度进行聚类分析，生成“地理位置簇”特征，或者计算样本到城市中心、关键地标的距离特征，以此捕捉房价的空间非线性规律；最后，在模型融合层面，可以考虑将不同模型的预测值进行加权融合，可能可以有效降低方差，提升预测的稳健性。