

HW4 Model Validation Report

运行代码：可以顺利运行对应小组的代码，kaggle 上分数 35.4 分。

数据处理：缺失值处理存在不合理的地方。

样本选择：该样本划分正确，无数据泄露问题。

建议：

韩方媛：

问题：1.缺失值含义混淆

```
# 补缺
df = df.fillna(0)
return df
```

数值型特征：填充 0 会扭曲数据分布，例如：建筑面积为 0 在现实中不可能存在；坐标距离为 0 表示就在市中心，但缺失值被错误解释；

分类特征：one-hot 编码的特征填充 0 表示“否”，但缺失值可能另有含义，例如将未知电梯状况等同于无电梯。

2.在特征提取过程中，缺失信息被过早处理

```
# 朝向
if "朝向" in df.columns:
    tmp = df["朝向"].fillna("").apply(lambda x: pd.Series(extract_room_direction(x)))
    tmp.columns = ["朝南", "朝北", "朝西", "朝东"]
    df = pd.concat([df, tmp], axis=1)

# 装修情况（精/简/其他/毛坯）
if "装修情况" in df.columns:
    tmp = df["装修情况"].fillna("").apply(lambda x: pd.Series(extract_room_fitment(x)))
    tmp.columns = ["精装修", "简装修", "其他装修", "毛坯"]
    df = pd.concat([df, tmp], axis=1)
```

后果：无法区分“真实为 0”和“信息缺失”，模型无法学习到缺失模式的规律，可能引入系统性偏差。

建议：数值型特征：避免直接填充 0，优先根据业务逻辑选择合理值。例如建筑面积可采用中位数填充，符合现实分布；分类特征：用“未知”“缺失”等特殊类别标记缺失值（如 `df["精装修"].fillna("未知")`），而非 0 或空字符串，明确区分“真实否”与“信息缺失”。

张海源：

1. 特征工程方面，可以增设特征交互项和非线性变化，源代码未见体现。

2. 代码中含不必要注释，提取数据时变量名有误：

```
# 小区楼型结构（如果有）
for struct_col in ["楼型_comm", "结构_comm", "建筑类型_comm"]:
    if struct_col in df.columns:
        tmp = df[struct_col].fillna("").apply(lambda x: pd.Series(extract_structure_comm(x)))
        tmp.columns = ["塔楼", "板楼", "平房"]
        df = pd.concat([df, tmp], axis=1)
    break
```

房价数据当中正确变量名应为“建筑结构_comm”而非“建筑类型_comm”。此外，也不含“楼型_comm”“结构_comm”变量。

郭德昊：

1. 在形式上，重复代码略多，缺乏函数封装。如在“户型解析、环线解析、特征工程”等流程中，房价预测和租金预测里都写了两遍，这不仅让代码冗长易错，也导致任何修改都必须两套代码里同步调整。建议在进行相同处理时，使用模块化代码以更简洁。
2. 特征工程选取上操作粗糙，许多特征通过正则提取，但没有对异常格式、匹配失败、非标准文本做处理。此外，在很多数据处理时，填充策略太不合理（缺失统一填为 0）。
3. Ridge/Lasso 的 α 搜索范围很小，很可能导致模型无法找到真正的最佳 α ，从而影响模型效果。

王泽疆：

1. 缺失值处理：替换简单的 `fillna(0)`

1a: 问题描述：原代码用 `df.fillna(0)` 填充所有缺失值，忽略特征意义（如总层数 $\neq 0$ 、电梯缺失 $\neq$ 无电梯）。原代码（`preprocess_price` 和 `preprocess_rent` 函数最后一行）：

原代码

```
# preprocess_price 最后一行
df = df.fillna(0)

# preprocess_rent 最后一行
df = df.fillna(0)
```

改进思路：按特征类型分层填充（数值型用中位数，-分类用众数），保留缺失信息。

1b: 原代码用均值填充环线缺失值（如 1 和 5 的均值 3 无地理意义）。

原代码：

```
mean_val = np.nanmean(X['环线_num'].values)
if np.isnan(mean_val):
    mean_val = 0.0
X['环线_num_filled'] = X['环线_num'].fillna(mean_val)
```

改进思路：改进思路：用众数填充有序分类特征。

2. 缺失异常值处理

改进思路：iqr 法或者取 $\ln$ 降低极端值对于模型的影响

3. 地理特征：新增商圈聚类

问题描述：原代码仅计算距市中心距离，浪费经纬度信息（商圈对房价 / 租金影响极大）。而且没有提取配套设施信息，浪费了有用特征。

原代码

```
def add_geo_features_price(df: pd.DataFrame, is_train: bool) -> pd.DataFrame:
    global PRICE_CENTER_LON, PRICE_CENTER_LAT
    df = df.copy()
    if ('lon' in df.columns) and ('lat' in df.columns):
        if is_train or PRICE_CENTER_LON is None:
            PRICE_CENTER_LON = df['lon'].median()
            PRICE_CENTER_LAT = df['lat'].median()
        dist = np.sqrt((df['lon'] - PRICE_CENTER_LON) ** 2 + (df['lat'] - PRICE_CENTER_LAT) ** 2)
        df['dist_to_center'] = dist.clip(0, 100)
    return df
```

改进思路：使用 k means 聚类，识别商圈或者使用对配套设施做文本处理

4. 特征选择

原代码未处理多重共线性（如建筑面积与套内面积）和低方差特征。

改进思路：1. 删除方差 <0.01 的低区分度特征；2. 删除相关系数 >0.8 的高冗余特征。

5. 参数调优：扩大搜索范围 + 增加迭代次数

改进思路：扩大 Ridge 的 alphas 范围多搜索几次